

2026학년도 2학기 언어데이터과학

제5강 데이터과학: 데이터의 정의와 범주

박수민

서울대학교 인문대학 언어학과

2026년 9월 16일 수요일

지난 시간에 배운 것

- 1 레코드와 필드: FS와 RS를 바꾸어 읽는 단위를 정하기
- 2 BEGIN — 패턴 {동작} — END, 배열과 반복문
- 3 요리책 한 권을 레시피 499개로 쪼개고 표(index.tsv)로 만들기

오늘의 목표

- 1 데이터의 정의와 범주를 설명할 수 있다.
- 2 언어데이터의 범위를 설명할 수 있다.
- 3 기본적인 기술통계량을 계산하고 해석할 수 있다.
- 4 하나의 요약값이 무엇을 감추는지 의심할 수 있다.

오늘의 출발점

4강 마지막에 얻은 한 문장

499 45.1242

“이 책의 레시피는 499개이고, 한 편은 평균 45단어다.”

이 한 문장에 숨은 질문

- index.tsv에 담긴 것은 **데이터**인가? 무엇이 데이터를 데이터로 만드는가?
- “45.1242”는 무엇을 말해 주고 **무엇을 감추는가?**
- 발표에서 “평균만 보고 그렇게 말할 수 있나요?”라는 질문을 받으면 무엇이라 답할 것인가?

오늘은 새 도구를 배우지 않는다. 지난시간에 만든 표를 **읽는 법**을 배운다.

사전 준비

터미널 입력

```
cd /workspaces/LDS2026  
awk -f awk/index.awk data/apicius/recipes-lf.txt > data/apicius/index.tsv  
head -n 3 data/apicius/index.tsv
```

실행 결과

number	title	words
1	FINE SPICED WINE	144
2	HONEY REFRESHER FOR TRAVELERS	82

오늘 쓰는 자료는 이 파일 하나다. 4강을 마치지 못했다면 `recipes-lf.txt`와 `awk/index.awk`를 먼저 만들어야 한다.

1 데이터

데이터의 정의
데이터의 범주

2 언어데이터

3 기술통계량

4 요약이 감추는 것

5 마무리

Data

“entities used as evidence of phenomena for the purposes of research or scholarship”

— C. Borgman. (2015.) Big Data, Little Data, No Data: Scholarship in the Networked World.

정의를 뜯어보기

entities 관찰하거나 기록할 수 있는 개체 — 음성 파일, 문장, 수치, 표의 한 행

evidence 무엇인가를 **뒷받침하기 위해** 쓰인다

phenomena 뒷받침의 대상이 되는 현상 — 언어 사용, 변화, 습득

research 체계적이고 **남이 검토할 수 있는** 탐구

정의에 없는 것

“수치”, “많다”, “컴퓨터”는 정의에 들어 있지 않다. 크기도 형식도 데이터의 조건이 아니다.

정의에 있는 것

데이터는 사물의 **종류**가 아니라 사물이 놓인 **자리**다. 무엇이든 증거로 쓰이는 순간 데이터가 된다.

같은 파일, 다른 지위

요리하는 사람에게

book.txt는 **읽을** 것이다.

- 필요한 곳만 펼쳐 본다
- 499라는 수는 필요 없다

우리에게

같은 파일이 **증거다**.


- “로마 요리의 72.9%에 후추가 들어간다”
- 그 주장을 뒷받침하려고 읽는다

그래서 생기는 의무

무엇을 주장하려는지 정해야 무엇을 세어야 할지가 정해진다.

- 4강에서 “레시피”를 [숫자]로 시작하는 레코드라고 **정의**한 것이 그 일이었다.
- 그 정의를 바꾸면 499도 72.9%도 달라진다.

우리가 만든 데이터의 계보



두 가지를 눈여겨볼 것

- 오른쪽으로 갈수록 **작아지고**, 대신 **답할 수 있는 질문**이 뚜렷해진다.
- 오른쪽으로 갈수록 **되돌릴 수 없다**. 45.1242에서 요리책으로 돌아갈 길은 없다.

그래서 데이터를 남길 때는 결과가 아니라 **화살표**(명령)를 남긴다.

네 가지 측정 척도

할 수 있는 계산이 늘어난다
↑

비율척도 (ratio) — 0이 “없음”

등간척도 (interval) — 간격
이 같다. 차를 잴 수 있다

순서척도 (ordinal) — 순서가 있
다. 크다/작다를 더할 수 있다

명목척도 (nominal) — 이름표. 같다/다르다만 말할 수 있다

위로 갈수록

아래 척도에서 할 수 있는 일은 위에서도 다 할 수 있다. 반대는 성립하지 않는다.

언어학에서의 예

척도	언어학 예시	0의 뜻	대푯값
명목	품사, 방언, 어족, 화자 성별	—	최빈값
순서	문법성 판단(1-5), 숙달도 등급	—	최빈값, 중앙값
등간	조사 연도, 섭씨 온도	임의로 정한 것	... 평균
비율	단어 수, 빈도, 발화 길이(초), F0(Hz)	진짜 “없음”	... 평균, 비율

오늘 다루는 words 열은?

단어 수는 **비율척도**다. 0단어는 진짜로 “글자가 없음”이고, 90단어는 45단어의 **두 배**라고 말할 수 있다. 그래서 평균을 낼 수 있다.

척도를 틀리면 생기는 일

품사 태그의 평균

NNG=1, VV=2, MAG=3으로 적고
평균 2.4를 구하면?

- 수는 나오지만 뜻이 없다.
- 명목척도에는 **순서가 없다.**

문법성 판단의 평균

1-5점 판단의 평균 3.7은?

- 순서척도지만 관행적으로 평균을 쓴다.
- 2와 3의 간격이 4와 5의 간격과 같다고 **가정하는 것이다.**
- 논쟁이 있으니, 쓴다면 그렇게 했다고 밝힌다.

기억할 것

컴퓨터는 무엇이든 평균 내 준다. 뜻이 있는지는 우리가 판단한다.

확인 질문

여기까지 정리

- 1 Borgman의 정의에서 “evidence”가 뜻하는 바는 무엇인가?
- 2 같은 파일이 데이터일 수도 아닐 수도 있다는 말은 무슨 뜻인가?
- 3 화자의 출신 방언은 어느 척도인가? 녹음 파일의 길이(초)는?
- 4 리커트 척도 응답의 평균을 구할 때 무엇을 가정하는가?

1 데이터

2 언어데이터
언어데이터의 범위
데이터를 남기는 법

3 기술통계량

4 요약이 감추는 것

5 마무리

무엇이 언어데이터인가

자연발생 (naturally occurring)

사람이 연구와 상관없이 만들어 낸 언어

- 문어 코퍼스, 신문, 웹 텍스트
- 일상 대화 녹음, 방송 자막
- 우리의 Apicius 요리책

유도·구성 (elicited)

연구를 위해 만들어 낸 언어

- 문법성 판단, 설문
- 그림 설명 과제, 낭독
- 반응시간·시선추적 실험

어느 쪽이 좋은가

- 자연발생: 실제로 쓰인 말이지만, 내가 보고 싶은 현상이 안 나올 수 있다.
 - 유도: 원하는 현상을 겨냥할 수 있지만, 실험실에서만 나오는 말일 수 있다.
- 둘은 경쟁 관계가 아니라 **서로의 빈 곳을 메운다.**

통제의 연속체



왼쪽으로 갈수록


맥락이 풍부하다.
대신 같은 상황을 다시 만들 수 없다.

오른쪽으로 갈수록

다시 만들 수 있다.
대신 **인위적**이다.

관찰 대상이 관찰당하는 줄 알면 말이 달라진다. — 관찰자의 역설

언어데이터는 층으로 쌓인다



층	현장 언어학	우리 실습
원자료	120517-001.wav	book.txt
전사	<u>hem ta m-y-aya maŋa?</u>	(이미 텍스트)
주석	1SG FUT 1SG-2-GIVE WHAT	[번호] 로 구분
분석	의문사가 제자리에 남는다	index.tsv
일반화	wh-in-situ 언어	“평균 45단어”

아래층 없이 위층만 남기면, 위층의 결정을 다시 검토할 수 없다.

층마다 해석이 들어간다

전사는 받아쓰기가 아니다

띄어쓰기를 어디에 둘지, 웃음소리를 적을지, “머...”를 적을지 — 모두 결정이다.

주석은 이론이다

“이것을 명사로 볼 것인가”는 데이터가 아니라 분석의 결과다. 형태소 분석 말뭉치는 이미 한 겹의 이론을 입고 있다. (8강, 10강)

그래서 원자료를 지우지 않는다

아래층을 버리면 위층의 결정을 다시 검토할 수 없다. `book.txt`를 지우지 않은 것, `recipes.txt`를 원본에서 새로 만든 것이 그 이유다.

메타데이터: 데이터에 대한 데이터

index.tsv의 첫 행

```
number title words
```

이 한 행이 없으면 144가 단어 수인지 각주 수인지 알 수 없다.

언어데이터에 필요한 최소한

- 무엇을(제목, 언어, ISO 639 코드)
- 누가(화자·저자, 조사자)
- 언제·어디서(수집 시점과 장소)
- 어떻게(수집·전사·주석 방법)
- 어떤 조건으로(이용 허락, 저작권)
- 어느 판본(출처 URL, 내려받은 날짜)

우리 슬라이드의 모든 수치에 “2026-09-07에 내려받은 파일”이라고 적어 둔 것이 메타데이터다.

FAIR 원칙

원칙	뜻	실천
F indable	찾을 수 있게	고유 식별자(DOI), 검색 가능한 메타데이터
A ccessible	가져올 수 있게	공개 저장소, 접근 조건 명시
I nteroperable	함께 쓸 수 있게	표준 형식(TSV, JSON, XML), 표준 용어
R eusable	다시 쓸 수 있게	이용 허락(라이선스), 만든 과정 기록

Accessible이 “공개”는 아니다

개인정보가 담긴 음성 자료를 아무나 내려받게 두는 것은 FAIR가 아니다. **접근 조건을 분명히 밝히는 것이 FAIR다.**

Wilkinson et al. (2016). Scientific Data 3:160018.

재현 가능한 연구

4강에서 이미 한 일

일곱 줄의 명령으로 요리책을 내려받아 분석할 파일까지 다시 만들었다. **데이터가 아니라 데이터를 만든 명령**을 남겼기 때문이다.

저장소에 남기는 것

- 스크립트(awk/, 나중에 *.ipynb)
- 출처와 내려받은 날짜
- 만드는 방법을 적은 문서

남기지 않는 것

- 큰 원본 데이터(data/는 .gitignore)
- 중간 산출물, 손으로 고친 표

손으로 고치면 재현할 수 없다

고칠 일이 있으면 **고치는 코드**를 쓴다.

확인 질문

여기까지 정리

- 1 자연발생 데이터와 유도 데이터는 각각 무엇을 얻고 무엇을 잃는가?
- 2 전사와 주석 중 이론이 더 많이 들어가는 층은 어느 쪽인가?
- 3 FAIR의 A는 “누구나 볼 수 있게”라는 뜻인가?
- 4 내 저장소에서 data/는 커밋하지 않는데, 그래도 재현이 가능한 이유는?

1 데이터

2 언어데이터

3 **기술통계량**
중심
산포
관계

4 요약이 감추는 것

5 마무리

하나의 수로 줄이기

기술통계량 (descriptive statistics)

가진 데이터를 **그대로 설명**하는 수. 없는 것을 짐작하지 않는다.

중심

어디쯤에 모여 있나?
평균, 중앙값, 최빈값

산포

얼마나 퍼져 있나?
범위, 사분위수, 표준편차

관계

같이 움직이나?
공분산, 상관계수

추론통계와의 차이

“이 책의 레시피는 평균 45단어다”는 기술통계다. “로마 요리는 평균 45단어다”는 여기에 없는 것까지 말하는 추론이고, 그러려면 이 책이 로마 요리의 **표본**이라는 근거가 필요하다.

세 가지 중심

평균 (mean)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- 모든 값을 쓴다
- 극단값에 끌려간다
- 등간·비율척도

중앙값 (median)

정렬해서 한가운데

- 순위만 쓴다
- 극단값에 흔들리지 않는다
- 순서척도부터

최빈값 (mode)

가장 자주 나온 값

- 세기만 한다
- 봉우리가 여럿일 수 있다
- 명목척도부터

척도와의 관계

위 척도의 대푯값일수록 정보를 많이 쓴다. 정보를 많이 쓸수록 흔들리기도 쉽다.

평균: 다 더해서 개수로 나눈다

터미널 입력

```
awk -F'\t' 'NR > 1 { n++; sum += $3 }  
            END { print n, sum, sum / n }' data/apicius/index.tsv
```

실행 결과

```
499 22517 45.1242
```

읽는 법

NR > 1로 머리글 행을 건너뛴다. 이 표에서는 첫 행이 데이터가 아니기 때문이다. AWK는 빈 변수를 0으로 보므로 sum을 미리 선언할 필요가 없다.

중앙값: 정렬이 필요하다

터미널 입력

```
awk -F'\t' 'NR > 1 { print $3 }' data/apicius/index.tsv | sort -n |  
awk '{ a[NR] = $1 }  
END { m = int(NR/2); print (NR%2) ? a[m+1] : (a[m]+a[m+1])/2 }'
```

실행 결과

33

처음 보는 문법: 조건 ? A : B

참이면 A, 거짓이면 B를 고르는 식이다 (if-else의 한 줄 형태). AWK는 0을 거짓으로 보므로 NR%2는 개수가 홀수일 때만 참이 된다.

평균은 한 번 훑으며 구할 수 있지만, 중앙값은 **전부 모아 정렬**해야 한다.

최빈값: 세어서 가장 많은 것

터미널 입력

```
awk -F'\t' 'NR > 1 { print $3 }' data/apicius/index.tsv |  
sort -n | uniq -c | sort -nr | head -n 3
```

실행 결과

```
18 17  
13 27  
13 19
```

읽는 법

3강에서 단어를 셀 때 쓴 `sort | uniq -c | sort -nr`가 그대로 쓰인다. 가장 흔한 길이는 **17단어**이고 그런 레시피가 18개다. 2위가 둘이라는 것도 보인다.

세 값이 다르다

대푯값	값	
평균	45.12	다 더해서 나눈 값
중앙값	33	250번째 레시피의 길이
최빈값	17	가장 흔한 길이


셋이 같아지려면

분포가 좌우대칭이고 봉우리가 하나여야 한다. 우리 데이터는 그렇지 않다는 뜻이다.

어느 쪽이 “전형적인 레시피”인가

평균 45단어짜리 레시피보다 **17단어짜리 레시피**가 훨씬 흔하다. 그림을 그려 보면 왜 그런지 한눈에 보인다.

레시피 길이의 분포



왼쪽에 몰려 있고 오른쪽으로 긴 꼬리가 있다. 이런 모양을 **오른쪽으로 치우쳤다고** 한다.

평균보다 짧은 레시피 세기

터미널 입력

```
awk -F'\t' 'NR > 1 { n++; if ($3 < 45.12) k++ }  
            END { printf "%d / %d = %.1f%%\n", k, n, 100 * k / n }' \  
data/apicius/index.tsv
```

실행 결과

```
313 / 499 = 62.7%
```

printf: 서식을 정해 출력하기

큰따옴표 안의 % 자리에 뒤의 값이 **순서대로** 들어간다. %d는 정수, %.1f는 소수점 아래 한 자리, %%는 글자 % 자체(서식 기호와 구별하려고 두 번 쓴다), \n은 줄바꿈이다. print와 달리 줄을 자동으로 바꾸지 않는다. (4강 count.awk 참고)

치우친 분포에서 평균이 뜻하는 것

“평균 45단어”를 정확히 말하면

레시피의 **62.7%**는 **평균보다 짧다**. 평균은 소수의 긴 레시피(273단어짜리도 있다)까지 포함해 나눈 값이다.

그래서 무엇을 적어야 하는가

평균만 적으면 “레시피는 대개 45단어쯤”으로 읽힌다. 실제로 가장 흔한 것은 17단어짜리다. 치우친 분포에서는 평균과 **중앙값을 함께** 적는다.

빈도·길이처럼 언어데이터의 많은 변수가 이렇게 치우쳐 있다.

다섯 수치 요약

터미널 입력

```
awk -F'\t' 'NR > 1 { print $3 }' data/apicius/index.tsv | sort -n |  
  awk '{ a[NR] = $1 }  
      END { print a[1], a[int(NR/4)+1], a[int(NR/2)+1],  
                a[int(3*NR/4)+1], a[NR] }'
```

실행 결과

```
0 20 33 61 273
```

최솟값	1사분위수 Q1	중앙값 Q2	3사분위수 Q3	최댓값
0	20	33	61	273

가운데 절반(Q1-Q3)이 20-61단어에 들어 있다. 이 폭 41을 **사분위범위**라 한다.

최솟값 0을 의심하라

터미널 입력

```
awk -F'\t' '$3 == 0' data/apicius/index.tsv
```

실행 결과

```
220      FOR ROASTS: PEPPER, LOVAGE, CORIANDER, CARRAWAY,      0
```

원본을 열어 보면

```
[220] FOR ROASTS: PEPPER, LOVAGE, CORIANDER, CARRAWAY,  
      SHALLOTS, MINT, YOLKS OF EGG, DATES, HONEY,  
      VINEGAR, BROTH, OIL AND WINE.
```

제목과 본문 사이에 빈 줄이 없다. 레시피 전체가 \$1에 들어가서 \$2가 비었다.

빈 값이 아니라 **우리 코드가 놓친 것이다**. 최솟값과 최댓값은 언제나 눈으로 확인한다.

편차와 표준편차

편차: 평균에서 떨어진 거리

$$x_i - \bar{x}$$

- 그냥 더하면 항상 0이 된다
- 그래서 **제곱**해서 더한다

분산과 표준편차

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}, \quad s = \sqrt{s^2}$$

- 제곱근으로 단위를 되돌린다
- s 는 데이터와 **같은 단위**(단어)다

왜 n 이 아니라 $n - 1$ 인가

평균을 데이터에서 구해 썼으므로 자유롭게 움직일 수 있는 값이 하나 줄어든다. n 이 크면 차이는 거의 없다. (499개에서는 34.7392 대 34.7740)

awk/stats.awk

```
1 BEGIN { FS = "\t" }
2 NR > 1 {
3     n++
4     x[n] = $3          # 표준편차를 구하려면 값을 기억해 두어야 한다
5     sum += $3
6 }
7 END {
8     mean = sum / n
9     for (i = 1; i <= n; i++) {
10         d = x[i] - mean
11         ss += d * d    # 편차의 제곱을 모은다
12     }
13     printf "개수      %d\n", n
14     printf "평균      %.2f\n", mean
15     printf "표준편차 %.2f\n", sqrt(ss / (n - 1))
16 }
```

실행 결과와 해석

터미널 입력

```
awk -f awk/stats.awk data/apicius/index.tsv
```

실행 결과

```
개수      499  
평균      45.12  
표준편차  34.77
```

눈여겨볼 곳

- 표준편차는 **평균을 먼저 알아야** 구할 수 있다. 그래서 두 번 훑는다.
- 34.77은 평균 45.12의 4분의 3이 넘는다. 매우 넓게 퍼져 있다는 뜻이다.

“ 45 ± 35 ”(10-80) 밖은 아래 21개, 위 75개로 한쪽에 몰렸다.

두 변수가 같이 움직이는가

공분산

$$\text{Cov}(X, Y) = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

- 둘 다 평균보다 크거나 작으면 곱이 양수
- 단위에 따라 값이 커졌다 작아졌다 한다

상관계수 (Pearson's r)

$$r = \frac{\text{Cov}(X, Y)}{s_X s_Y}$$


- 표준편차로 나누어 단위를 없앤다
- 언제나 $-1 \leq r \leq 1$

크기를 읽는 대략의 기준

$|r| < 0.2$ 거의 없음 0.2-0.4 약함 0.4-0.7 중간 0.7 이상 강함
 $r = 0$ 은 직선 관계가 없다는 뜻일 뿐이다.

Zipf의 약어 법칙

- 최소 노력의 원리
- AND, THE, WITH 대 PEPPERCORNS



길이별 단어 종류 수: 130, 350, 413, 474, 375, 279, 217, 108

3강의 파일로 확인

word-freq.txt에는 대문자 단어
2,434종이 빈도와 함께 들어 있다.

awk/corr.awk: 상관계수 구하기

```
1 {
2     x = length($2)           # 단어의 길이
3     y = $1                   # 그 단어의 빈도
4     n++
5     sx += x;   sy += y
6     sxy += x * y
7     sxx += x * x;   syy += y * y
8 }
9 END {
10     den = sqrt(n*sxx - sx*sx) * sqrt(n*syy - sy*sy)
11     r = (n*sxy - sx*sy) / den
12     printf "n=%d   r=%.4f\n", n, r
13 }
```

합만 모아 두면 한 번 훑고도 상관계수를 구할 수 있다.

두 번 재 보기

터미널 입력

```
awk -f awk/corr.awk data/apicius/word-freq.txt  
# y = log($1)/log(10) 으로 고쳐서 다시  
awk -f awk/corr-log.awk data/apicius/word-freq.txt
```

n=2434 r=-0.1383

길이와 빈도

n=2434 r=-0.2949

길이와 log(빈도)

같은 데이터인데 왜 달라지는가

상관계수는 **직선 관계**만 잰다. 빈도는 1부터 1265까지 몇 자릿수에 걸쳐 있어서 직선이 아니다. 로그를 취해 자릿수를 펴 주면 관계가 더 잘 드러난다.

두 값 모두 음수다. 긴 단어일수록 덜 쓰인다는 경향은 이 작은 책에서도 보인다.


확인 질문

여기까지 정리

- 1 평균 45.12와 중앙값 33 중 “전형적인 레시피”에 가까운 것은? 왜인가?
- 2 표준편차를 구할 때 편차를 그냥 더하지 않고 제곱하는 이유는?
- 3 최솟값이 0으로 나왔을 때 가장 먼저 할 일은?
- 4 $r = -0.1383$ 과 $r = -0.2949$ 는 서로 다른 데이터에서 나온 값인가?
- 5 $r = 0$ 인 두 변수는 아무 관계가 없다고 말해도 되는가?

- 1 데이터
- 2 언어데이터
- 3 기술통계량
- 4 요약이 감추는 것**
그림을 그려 보기
층을 나누어 보기
- 5 마무리

같은 통계량, 다른 데이터



네 데이터의 통계량은 모두 같다

$$\bar{x} = 9.00, \bar{y} = 7.50, s_x = 3.32, s_y = 2.03, r = 0.82$$

F. J. Anscombe. (1973.) Graphs in Statistical Analysis. The American Statistician 27(1).

Anscombe이 말한 것

네 그림이 보여 주는 것

- I 직선 관계에 흠어짐이 있다
- II 관계가 있지만 **곡선**이다
- III 완벽한 직선 + 이상치 하나
- IV x 가 거의 한 값 + 점 하나가 전부를 만든다

교훈

- 1 통계량은 데이터를 **대신하지 않는다**
- 2 요약하기 전에 그려 본다
- 3 값 하나가 결과를 좌우하는지 확인한다

우리 데이터로 말하면

“평균 45.12, 표준편차 34.77”만 적어 놓았다면 앞의 히스토그램(왼쪽으로 몰린 봉우리와 긴 꼬리)은 보이지 않았을 것이다. 7강에서 이런 그림을 코드로 그린다.

awk/pepper.awk: 길이 구간별 후추 사용률

```
1 BEGIN {
2     RS = "\n\n\n+"; FS = "\n\n"
3     split("0-20 21-33 34-61 62-273", lab, " ") # 사분위로 나눈 네 구간
4 }
5 $1 ~ /^\[0-9]+\$/ {
6     n = split($2, w, " ") # 이 레시피의 단어 수
7     g = (n <= 20) ? 1 : (n <= 33) ? 2 : (n <= 61) ? 3 : 4
8     tot[g]++
9     if ($2 ~ /PEPPER/) hit[g]++
10 }
11 END {
12     for (g = 1; g <= 4; g++)
13         printf "%-7s %3d/%3d %2.0f%%\n", lab[g], hit[g], tot[g], 100*hit[g]/tot[g]
14 }
```

구간의 경계 20, 33, 61은 앞에서 구한 Q1, 중앙값, Q3이다. : 뒤에 ?를 이어 붙이면 “아니면 그다음 조건”이 되어 else if처럼 읽는다.

후추 72.9%의 실체

터미널 입력

```
awk -f awk/pepper.awk data/apicius/recipes-lf.txt
```

실행 결과

0-20	81/132	61%
21-33	83/124	67%
34-61	95/122	78%
62-273	105/121	87%

4강의 결론은 “레시피 499개 중 364개(72.9%)에 후추가 들어간다”였다.

숨은 변수

길이를 나누어 보면

짧은 레시피는 61%, 긴 레시피는 87%다. 72.9%는 그 사이 어딘가의 평균일 뿐이다.

- 긴 레시피는 재료를 많이 **적었을** 뿐, 후추를 더 많이 **썼다**는 보장이 없다.
- 기록의 길이가 사용 여부와 얽혀 있다. 이런 변수를 **교란변수**라 한다.

비율을 볼 때의 습관

전체 비율 하나를 보면 언제나 되묻는다. “이 안에서 서로 다른 집단이 섞여 있지 않은가?”

이 습관이 다음 슬라이드에서 훨씬 큰 문제를 드러낸다.

학과를 하나씩 보면

논문이 든 가상의 대학이다. 학과가 둘뿐이고 1,200명이 지원했다. 학과마다 남녀를 따로 세어 본다.

학과		지원	합격	합격률
machismatics	남성	400	200	50%
	여성	200	100	50%
social warfare	남성	150	50	33%
	여성	450	150	33%

여기까지 읽은 것

두 학과 모두 남성과 여성의 합격률이 소수점까지 같다. 어느 학과도 성별에 따라 다르게 뽑지 않았다.

Bickel, Hammel & O'Connell. (1975.) Science 187(4175), 398-404, Table 2.
<https://doi.org/10.1126/science.187.4175.398>

그런데 둘을 합치면

	지원	합격	합격률
남성	$400 + 150 = 550$	$200 + 50 = 250$	45.5%
여성	$200 + 450 = 650$	$100 + 150 = 250$	38.5%



학과별로는 차이가 없었는데 7%p가 생겼다

합격자는 250명으로 **같다**. 그런데 지원자 수가 달라 나누는 수가 달라졌다.

Simpson's paradox

각 집단 안에서는 없던(또는 반대였던) 차이가, 집단을 **합치면** 나타나거나 뒤집히는 현상.
1951년 통계학자 E. H. Simpson이 정리한 데서 이름을 얻었다.

왜 이런 일이 생기는가



전체 합격률은 두 학과 합격률의 **가중평균**이다

칸의 높이는 합격률, 폭은 **지원자 수** (진한 칸 machismatics, 연한 칸 social warfare)다. 높이는 남녀가 똑같다. 폭이 다를 뿐인데 점선(전체 합격률)의 위치가 갈린다.

남성은 합격률 50%인 학과에 73%가, 여성은 33%인 학과에 69%가 몰렸다.

실제 버클리 데이터 (1973년 가을 대학원)

전체 집계 (지원 12,763건)

	지원	합격	합격률
남성	8,442	3,738	44%
여성	4,321	1,494	35%

학과별로 나누어 보니

85개 학과 중 여성에게 불리한 쪽으로
뚜렷한 학과는 **4개**, 남성에게 불리한
쪽은 **6개**였다.

논문의 설명

“여성 지원자의 비율은 **들어가기 어려운 학과**에서 높고, 쉬운 학과에서 낮은 경향이 있다.”
전체 격차는 입학 심사가 아니라 **지원 분포**에서 생겼다.

여기까지가 널리 알려진 이야기다. 그리고 많은 소개 글이 **바로 이 자리에서** 끝난다.

여기에서 멈추면

어느 대중 과학 잡지의 마무리

“어느 특정 학과도 남학생을 선호하지 않았고 오히려 과별로 봤을 때는 여학생이 많이 합격했는데도, 합격률이 낮은 과에 여학생이 많이 지원하고 합격률이 높은 과에 남학생이 많이 지원한 것이 심슨의 역설을 불러왔던 거죠.”

— 《수학동아》 2020년 11월호

이 마무리가 던지지 않은 질문

왜 여성은 합격률이 낮은 학과에 많이 지원했는가?

- 이 질문을 빼면 “학과별로는 차별이 없었다”가 “차별이 없었다”로 미끄러진다.
- 같은 구조의 사례에 《과학동아》(2008)가 붙인 제목은 “남성차별이 여성차별로 둔갑?”이었다.

원 논문은 거기에서 끝나지 않았다

Bickel, Hammel & O'Connell (1975), p. 403

“The absence of a demonstrable bias in the graduate admissions system **does not give grounds for concluding that there must be no bias anywhere else** in the educational process...”

같은 쪽, 논문의 요약

“Women are **shunted** by their socialization and education toward fields of graduate study that are generally more crowded, less productive of completed degrees, and less well funded, and that frequently offer poorer professional employment prospects.”

여성은 사회화와 교육을 거치며, 대체로 더 붐비고 학위를 마치는 비율이 낮고 재정 지원이 적으며 전문직 전망도 나쁜 분야로 **떠밀린다**.

논문이 찾아낸 것은 차별의 부재가 아니라 **차별의 자리**였다.

어디에서 멈출 것인가

층을 나눈 결과가 말해 주는 것

“차별이 없다”가 아니라 “격차가 어느 단계에서 생겼는가”이다. 질문이 입학 심사에서 지원 분포로 옮겨 갔을 뿐, 사라진 것이 아니다.


멈추는 자리가 결론을 만든다

- 보고 싶은 답이 나오는 자리에서 분석을 멈추면, 그 자체가 **은폐**가 된다.
- 논문은 대학이 그 앞 단계를 조사하고 바로잡아야 한다고 제안하며 끝난다.

덧붙여, 같은 기사는 버클리가 “고소당했”다고 적었지만 소송은 **없었다**. 걱정만 있었을 뿐이다.

A. Reinhart. (2016.) Simpson's Paradox and Statistical Urban Legends.
<https://www.refsmmat.com/posts/2016-05-08-simpsons-paradox-berkeley.html>

상관관계는 인과관계가 아니다



r 이 크게 나왔을 때의 가능성

- 1 x 가 y 의 원인이다
- 2 y 가 x 의 원인이다 (어휘력이 좋아 읽는다)
- 3 제3의 변수가 둘 다의 원인이다
- 4 우연이다

기술통계로 할 수 있는 말

“함께 움직인다”까지다. 원인을 말하려면 다른 근거가 필요하다.

- 12-13강에서 ‘완전’과 ‘아주’를 연령·성별로 **나누어** 비교하는 것이 오늘 배운 습관의 연습이다.

1 데이터

2 언어데이터

3 기술통계량

4 요약이 감추는 것

5 마무리

요약

다음 시간 예고

과제

요약값을 낼 때의 점검표

보고하기 전에

- 1 이 변수는 어느 **척도**인가? 이 계산이 뜻이 있는가?
- 2 분포를 **그려 보았는가**? 봉우리가 하나인가, 치우쳤는가?
- 3 평균만 적지 말고 **중앙값·범위**도 함께 적었는가?
- 4 **최솟값과 최댓값**을 눈으로 확인했는가?
- 5 집단이 섞여 있지 않은가? **나누어** 보아도 같은 방향인가?
- 6 나눈 뒤에 생긴 질문을 덮고 **멈추지** 않았는가?
- 7 이 수를 만든 **명령**이 저장소에 남아 있는가?

처음의 질문으로

“평균만 보고 그렇게 말할 수 있나요?” — “중앙값 33, 62.7%가 평균 미만입니다.”

오늘 배운 것

데이터

- 증거로 쓰이는 순간 데이터가 된다
- 네 가지 척도: 명목·순서·등간·비율
- 척도가 가능한 계산을 정한다

언어데이터

- 자연발생 — 유도의 연속체
- 원자료·전사·주석·분석의 층
- 메타데이터, FAIR, 재현 가능성

기술통계량

- 중심: 45.12 / 33 / 17
- 산포: 0 / 20 / 33 / 61 / 273, $s = 34.77$
- 관계: r 은 직선 관계만 잰다

요약이 감추는 것

- Anscombe: 그려 보아야 안다
- 교란변수와 심슨의 역설
- 멈추는 자리가 결론을 만든다
- 상관 $\neq$ 인과

다음 시간에 배울 것 (9월 21일 월요일)

제6강 Python 활용 (1) 수치 연산과 배열

오늘 AWK로 여러 줄에 걸쳐 한 일을 numpy로는 이렇게 쓴다.

```
import numpy as np

words = np.loadtxt('data/apicius/index.tsv', delimiter='\t',
                  skiprows=1, usecols=2)
print(words.mean(), np.median(words), words.std(ddof=1))
```

그때 확인할 것

- 같은 데이터에서 **같은 값**(45.12, 33, 34.77)이 나오는가?
- $ddof=1$ 은 오늘 이야기한 $n - 1$ 이다. 기본값은 n 이니 주의한다.

[숙제02] AWK 연습

제출

- 제출 기한: **2026-09-23 12:00 (다음 주 수요일 정오)**
- 제출 연장: 2026-09-22 12:00 (화요일 정오)까지 이메일로 신청한다.
- 제출 방법: awk/ 아래 스크립트를 저장소에 push한다.
- 데이터 파일(data/)은 커밋하지 않는다.

오늘 배운 것과 이어서

레시피 카드를 만들 때 **빈 파일**이 생기지 않는지 확인해 본다. 220번 레시피처럼 형식이 어긋난 자료가 어디에 또 있는지 찾아보는 것도 좋다.

막히면 eTL Q&A 게시판에 질문한다. (답변 마감: 9월 22일 화요일 12:00)