

2026학년도 2학기 언어데이터과학

제8강 코퍼스언어학: 빈도와 생산성

박수민

서울대학교 인문대학 언어학과

2026년 9월 28일 월요일

지난 시간에 배운 것

- 1 표를 표인 채로 다루고, 묶고, 붙이고, 결측값을 살폈다.
- 2 seaborn으로 분포와 관계를 그리고 파일로 남겼다.
- 3 4강부터 7강까지 **같은 요리책**을 세 도구로 세 번 분석했다.

오늘의 목표

- 1 토큰·타입·문서 빈도를 구별해서 정확하게 보고할 수 있다.
- 2 길이가 다른 텍스트끼리 공정하게 비교할 수 있다.
- 3 접사가 얼마나 “살아 있는지”를 수치로 잴 수 있다.
- 4 6강에서 만난 **단발어** 1,118개가 어디에 쓰이는지 안다.

ANOTHER 116은 무엇을 센 수인가

7강에서 본 실행 결과

```
first
ANOTHER      116
SAUCE         37
A             25
TO            23
BOILED        14
Name: count, dtype: int64
```

116은 셋 중 무엇인가

- 1 ANOTHER로 시작하는 제목이 **116** 가지인가?
- 2 ANOTHER라는 단어가 **116번** 나왔는가?
- 3 ANOTHER로 시작하는 레시피가 **116** 편인가?

셋은 서로 다른 수다

제목의 최빈값은 ANOTHER WAY로 그것만 29번 나온다. 그러니 “116가지”는 아니다. 그렇다면 나머지 둘 중 무엇인가?

오늘은 그동안 센 수가 무엇이었는지를 되묻는다. 답은 마지막 프레임에서.

오늘의 두 코퍼스

한국어 동요 10편

- 문서 10편, 토큰 185개, 타입 104개
- 형태소로 나뉘어 있어 손으로 셀 수 있다

Apicius

- `recipes.txt` 토큰 21,328개, 타입 2,434개
- 레시피 카드 499편 ([숙제02]에서 만든 것)

오늘 새 데이터는 없다

작은 것으로 개념을 세우고, 큰 것으로 확인한다. Apicius는 4강 AWK, 6강 numpy, 7강 pandas가 차례로 다룬 바로 그 파일이다.

1 무엇을 세는가

토큰과 타입

문서 빈도

연구 사례

세는 단위

2 어휘 다양성

3 지프의 법칙

4 생산성

5 마무리

동요 코퍼스 10편

형태소로 나눈 동요 10편

- [0] 반짝 반짝 작 은 별 아 름답 게 비치 네 동쪽 하늘 에서 도 서쪽 하늘 에서 도
- [1] 햇별 은 펑펑 모래알 은 반짝 모래알 로 밥 을 짓 고 조약돌 로 소반 놓 아
- [2] 파랑 은 하늘 파랑 은 하늘 꿈 이 드리우 은 작 은 언덕 에 아기 염소 여럿 이 풀 을 뜯 고 놀 아요
- [3] 깊 은 산 속 웅달샘 누구 가 오 아서 먹 나요 맑 고 맑 은 웅달샘 누구 가 오 아서 먹 나요
- [4] 산 토끼 토끼 야 어디 로 가 느냐 깡충 깡충 뛰 면서 어디 로 가 느냐
- [5] 곰 세 마리 가 한 집 에 있 어 아빠 곰 엄마 곰 아기 곰
- [6] 나비 야 나비 야 이리 날 아 오 너라 노랑 나비 희 은 나비 춤 을 추 며 오 너라
- [7] 산 위 에서 불 는 바람 시원하 은 바람 그 바람 은 좋 은 바람 고맙 은 바람
- [8] 루돌프 사슴 코 는 매우 반짝이 는 코 만일 너 가 보 았 다면 불 불 는다 하 였 겠 지
- [9] 푸르 은 하늘 은하수 하얗 은 쪽배 에 예수 나무 한 나무 토끼 한 마리

관찰 문서 10편, 토큰 185개, 타입 104개

물음 이 셋은 각각 무엇을 센 수인가?

[0]행의 앞 다섯



토큰 5개
나타난 낱말을 센다

타입 4가지

‘반짝’이 하나로 합쳐진다

동요 10편 전체로는

토큰 185개 — 타입 104가지

“타입 빈도”는 두 가지 뜻으로 쓰인다

- 코퍼스 전체의 타입 수 V
- 어떤 패턴에 속하는 서로 다른 형태의 수 (§4에서 쓸 뜻)

Berg (2014): 규칙 동사와 불규칙 동사

Thomas Berg. (2014). On the Relationship between Type and Token Frequency. *Journal of Quantitative Linguistics* 21(3), 199–222.

Table 7. Type and token frequencies of regular and irregular verbs (simple past, first person singular).

Verb / Frequency	Type 0		Type 1		Token	
	<i>n</i>	%	<i>n</i>	%	<i>n</i>	%
regular	4841	88.1%	2844	94.6%	76,486	43.8%
irregular	653	11.9%	163	5.4%	98,248	56.2%

Type 0 사전에 오른 단어의 가짓수

Type 1 텍스트에 실제로 쓰인 가짓수

Token 텍스트에 쓰인 낱말의 개수

물음이 성립하지 않는다

규칙 동사는 타입의 **94.6%**인데
토큰은 **43.8%**다.

“영어에서 규칙 동사의 빈도가 높은가, 불규칙 동사의 빈도가 높은가”는 **무엇을 세는지** 말하기 전에는 답할 수 없는 물음이다.

‘바람’이 많은가, ‘산’이 많은가

‘바람’이 나오는 문서

[7] 산 위 에서 불 는 바람 시원하 은 바람 그 바람 은 좋 은 바람 고맙 은 바람

‘산’이 나오는 문서

[3] 깊 은 산 속 웅달샘 누구 가 오 아서 먹 나요 맑 고 맑 은 웅달샘 누구 가 오 아서 먹 나요

[4] 산 토끼 토끼 야 어디 로 가 느냐 광충 광충 뛰 면서 어디 로 가 느냐

[7] 산 위 에서 불 는 바람 시원하 은 바람 그 바람 은 좋 은 바람 고맙 은 바람

세는 방법에 따라 순위가 뒤집힌다

나타난 횟수로는 바람 5 > 산 3. 그러나 나타난 문서로는 바람 1 < 산 3.

문서 빈도

0	1	2	3	4
5	6	7	8	9

'산'이 든 문서 3개

정의

그 단어가 **적어도 한 번** 나타난 문서의 수. 한 문서에 몇 번 나와도 1로 센다.

단어	토큰 빈도	문서 빈도	문서당
바람	5	1	5.00
하늘	5	3	1.67
곰	4	1	4.00
나비	4	1	4.00
산	3	3	1.00
반짝	3	2	1.50
토끼	3	2	1.50

토큰 빈도 전체 사용량을 센다

문서 빈도 널리 퍼진 정도를 센다

같은 코퍼스, 네 번의 역전

단어	토큰	문서	문서당
THE	985	324	3.04
PEPPER	461	364	1.27
WINE	340	242	1.40
OIL	331	298	1.11
ADD	209	147	1.42
SERVE	174	171	1.02
THEM	157	94	1.67
RUE	99	96	1.03

네 쌍 모두 순위가 뒤집힌다

위가 토큰 빈도는 높는데 문서 빈도는 낮다. 동요에서 본 ‘바람’ 대 ‘산’이 499 편에서도 그대로 일어난다.

읽는 법

THE는 몇몇 레시피에 **몰려** 나오고, PEPPER는 거의 모든 레시피에 **고르게** 퍼져 있다. 요리책에서 후추는 기능어에 가깝다.

무엇을 세고 있는가

터미널 입력 — 셋 다 “PEPPER를 센다”

```
grep -o "PEPPER" data/apicius/recipes.txt | wc -l
grep    "PEPPER" data/apicius/recipes/*.txt | wc -l
grep -l "PEPPER" data/apicius/recipes/*.txt | wc -l
```

실행 결과 — 셋 다 다른 수가 나온다

```
469
367
366
```

grep -o 부분 문자열까지 센다. PEPPERED 안의 PEPPER를 센 469다

grep 파일이 아니라 맞은 행을 센다. 367은 문서 수가 아니다

grep -l 맞은 파일 이름만 낸다. 문서 빈도는 366이다

단어 단위로 세면 토큰 빈도는 467이다. 명령 하나가 세는 것을 바꾼다.

이정복 (2010): “게시글 수”

이정복. (2010). <인터넷 통신 공간의 여성 비하적 지시 표현>. 《사회언어학》 18(2), 215-247.

구분	김여사	김기사	합
이야기 게시판	677(93.1)	50(6.9)	727개(100%)
토론 게시판	599(87.4)	86(12.6)	685개(100%)

<표 2> ‘김여사’와 ‘김기사’의 쓰임 차이 [게시글 수(백분율)]

센 것

“게시글 수”
⇒ 문서 빈도



93.1%와 6.9%는 무엇에 대한 백분율인가

- 분모 727은 ‘김여사’ 또는 ‘김기사’가 든 글의 수다. **전체 게시글 수가 아니다.**
- 두 집합이 겹치면 한 글이 **양쪽에 한 번씩** 세어진다. 그러면 “100%”라는 말이 성립하지 않는다.

문서 빈도에 백분율을 붙으려면 분모가 **전체 문서 수**여야 한다. 두 키워드의 합은 분모가 될 수 없다.

김민령·이승호 (2024): 같은 논문의 두 “빈도”

김민령, 이승호. (2024). <인터넷 커뮤니티에서 신도시 ‘동탄’ 관련 연어 사용에 대한 고찰>. 《사회언어학》 32(2), 109-140.



[그림 2] — 문서 빈도

본문이 “‘동탄’을 포함하는 게시물”이라 밝혔다.

[그림 3] — 무엇인가

“가장 많이 검색되는” 것의 횟수.
문서인가, 출현인가?

축 이름 count는 무엇을 센 값인지 말해 주지 않는다. 7장에서 `ax.set_xlabel()`로 축 이름을 'words per recipe'라 고쳐 단 까닭이다.

더하면 안 되는 수

김민령, 이승호. (2024). 《사회언어학》 32(2), 109-140. <표 3>

<표 3> 2020년 1월 ~ 2021년 9월 출현 표현 빈도

동탄 연어 표현	빈도
동탄맘	130
동탄충	61
동탄급	31
동탄맘카페	7
동탄미시	4
동탄유부녀	3
동탄아줌마	1

일곱을 더해 보면

$130 + 61 + 31 + 7 + 4 + 3 + 1 = \mathbf{237}$
 그런데 같은 기간 <표 2>의 연어 빈도 합은
206이다.

두 표가 맞지 않는다

‘동탄맘’이 ‘동탄맘카페’를 삼켰을 수도
 있고, 두 표가 같은 말 ‘빈도’로 서로 다른
 것을 썼을 수도 있다.

문서 빈도는 서로 겹칠 수 있으므로 **더해서 100%를 만들 수 없다.**

부분 비율들의 평균

김민령, 이승호. (2024). 《사회언어학》 32(2), 109-140. <표 2>

<표 2> 2020년 1월 ~ 2021년 9월

시기	동탄 빈도	언어 빈도	비율	시기	동탄 빈도	언어 빈도	비율
2020_01	116	0	0.000%	2021_01	382	14	3.665%
2020_02	120	0	0.000%	2021_02	285	6	2.105%
2020_03	96	2	2.083%	2021_03	244	6	2.459%
2020_04	106	6	5.660%	2021_04	264	12	4.545%
2020_05	136	0	0.000%	2021_05	645	14	2.171%
2020_06	132	4	3.030%	2021_06	572	12	2.098%
2020_07	305	8	2.623%	2021_07	495	22	4.444%
2020_08	302	16	5.298%	2021_08	665	26	3.910%
2020_09	361	10	2.770%	2021_09	402	10	2.488%
2020_10	365	28	7.671%				
2020_11	419	6	1.432%				
2020_12	403	4	0.993%				

<표 2>에서 2021년 10월 이전에 연도별 키워드 '동탄'의 사용 빈도와 언어로서 사용된 패턴의 빈도를 살펴보면, 이 시기에 출현한 키워드의 2.83%가 언어로서 사용된 것을 확인할 수 있다¹¹⁾.

논문의 2.83%

월별 비율 21개 (0.000%, 0.000%, 2.083%, 5.660%, ...)의 단순평균이다.

전체의 비율은 3.02%다

$\frac{206}{6,815} = 3.02\%$
달마다 글의 수가 다르므로
가중평균이라야 한다.

5강 버클리 대학원 합격률에서 본 그 문제다. **부분의 평균은 전체의 비율이 아니다.**

그러면 문서 빈도는 어디에 쓰는가

토큰 빈도가 같아도 문서 빈도는 다르다

THYME은 34편에 **한 번씩** 흩어져 있고, PEAS는 14편에 **몰려** 있다. 그 14편 가운데 13편이 185-201번, 요리책의 **콩 요리 대목**이다.

단어	토큰	문서	편당	IDF
THYME	34	34	1.0	2.69
PEAS	33	14	2.4	3.57

이것이 TF-IDF의 IDF다

문서 빈도의 **역수**에 로그를 씌워($IDF = \log \frac{499}{df}$) 흔한 말의 무게를 낮춘다. **19강**에서 영화평을 수치로 바꿀 때, **20강**에서 문서끼리 닮은 정도를 잴 때 쓴다.

토큰 빈도만 보면 둘은 같은 말이다. **문서 빈도가 주제를 드러낸다.**

검색 결과 건수를 빈도로 쓸 때

Adam Kilgarriff. (2007). Googleology is Bad Science. *Computational Linguistics* 33(1), 147–151.

앞의 두 논문이 실제로 센 것

“게시글 수”도 월별 빈도도 **검색 결과 건수**다. 말뭉치를 대신해서 쓴 것이다.

그래서 쓴다

- 내가 만들 수 없는 크기의 자료에 닿는다
- 작은 말뭉치에서 0이 나오는 신조어도 셀 수 있다

그러나

- 토큰이 아니라 **문서**를 센 수다
- **어림값**이고 중복 게시물이 부풀린다
- **분모**를 몰라 비율을 낼 수 없다

내일 다시 검색하면 다른 수가 나온다. **검색식과 검색한 일시**를 반드시 적는다.

무엇을 하나로 셀 것인가

대소문자 PEPPER와 pepper는 한 타입인가, 두 타입인가

굴절형 먹다 / 먹었다 / 먹는을 한 단어로 볼 것인가

합성어 ‘김치볶음밥’ 안의 ‘밥’을 셀 것인가

문장부호 하이픈으로 이은 말, 따옴표, 줄표를 어떻게 자를 것인가

정답은 없다. 적어 두는 것이 있을 뿐이다

어느 쪽을 골라도 된다. 다만 **무엇을 골랐는지 적지 않으면** 남이 여러분의 수를 다시 만들어 낼 수 없다.

이 물음은 두 번 더 온다

- **9강:** 글자 하나가 무엇인가. ‘바람’의 길이가 2인가 6인가.
- **10강:** 한국어는 공백만으로 단어를 셀 수 없다.

확인 질문

여기까지 정리해 봅시다

- 1 동요의 ‘바람’에 대해 토큰 빈도와 문서 빈도를 각각 말해 보자.
- 2 Berg의 표에서 규칙 동사가 타입 94.6%, 토큰 43.8%인 것을 한 문장으로 설명해 보자.
- 3 grep과 grep -l의 결과가 다른 까닭은 무엇인가?
- 4 동요 코퍼스가 ‘와서’를 ~~오~~ ~~아서~~로 적어 둔 까닭은 무엇인가?
- 5 “이 단어는 코퍼스에 500번 나왔다”에 무엇을 덧붙여야 하는가?

1 무엇을 세는가

2 어휘 다양성

TTR

STTR

청어노걸대

3 지프의 법칙

4 생산성

5 마무리

TTR — 타입을 토큰으로 나누기

정의 — **Type-Token Ratio**, 타입-토큰 비

$$\text{TTR} = \frac{\text{타입 수 } V}{\text{토큰 수 } N}$$

노트북 입력

```
t = open('songs.txt').read().split()
print(len(t), len(set(t)))
print(len(set(t)) / len(t))
```

실행 결과

```
185 104
0.5621621621621622
```

6강의 set과 7강의 `nunique()`가 하던 바로 그 일이다. 어휘가 얼마나 다양한지를 재려는 것이다.

TTR은 길이를 켤다

토큰 수 N	500	1,000	2,000	5,000	10,000	17,156
타입 수 V	271	434	690	1,023	1,315	1,583
TTR	0.5420	0.4340	0.3450	0.2046	0.1315	0.0923

Apicius 레시피 카드 코퍼스의 앞 N 토큰만 잘라서 계산


같은 코퍼스인데 0.54에서 0.09가 되었다

TTR은 어휘 다양성이라기보다 **표본 크기의 함수**에 가깝다. 길이가 다른 두 텍스트의 TTR을 그대로 견주면 안 된다.

그러므로

동요 0.562와 Apicius 0.0923을 놓고 “동요가 여섯 배 다양하다”고 말할 수 없다. 동요를 500토큰까지 늘리면 0.54 언저리에 놓인다.

코퍼스를 키우면 어휘는 어떻게 느는가



타입은 계속 늘지만 점점 느리게 는다


토큰이 34배 (500 → 17,156)가 되는 동안 타입은 **5.8배** (271 → 1,583)밖에 되지 않았다.
그래서 오른쪽 TTR 곡선이 내려간다.

그런데 왼쪽 곡선은 끝내 **평평해지지 않는다**. 까닭은 §3의 꼬리에서 본다.

STTR — 같은 자로 재기

정의 — **Standardised Type-Token Ratio**, 표준화 타입-토큰 비

일정한 길이의 구간(흔히 1,000토큰)마다 TTR을 따로 구해 **평균**한다. 모든 구간의 N 이 같으므로 길이의 영향을 받지 않는다.



함께 적어야 할 것 셋

구간 길이 **1,000토큰**, 구간 수 **17개**, 남은 **156토큰**은 버렸다.

정성훈·도정업 (2021): 어휘 다양성으로 난이도를 재다

정성훈, 도정업. (2021). <외국어 교재로서의 『청어노걸대』에 대한 계량적 연구>. 《한글》 82(4), 999–1030.

본 연구에서는 전체 『청어노걸대』를 대상으로, 보다 정밀한 계량적 분석 방법을 적용하여 『청어노걸대』에서 나타나는 외국어 교재로서의 특성을 밝히려고 한다. 우선 기본적으로 전체 『청어노걸대』에 나타나는 어휘 항목의 유형과 빈도를 추출하고 이에 대한 빈도 분석(frequency analysis)을 수행한다. 일반적으로 유형과 빈도를 추출한 후, TTR(Type/Token Ratio)을 측정하는데, 이러한 유형과 빈도 비율은 텍스트에 나타나는 ‘어휘의 다양성(lexical richness)’을 보여준다.³⁾ 본 연구에서는 외국어 교재로서 『청어노걸대』가 갖고 있는 ‘어휘의 다양성’을 측정하고, 이를 다시 권별로

3) ‘어휘의 다양성’은 외국어 교재가 갖는 특징 중 하나인데, 일반적으로 텍스트의 양이 많아질수록 TTR 값은 작게 수렴하는 것으로 알려져 있다. 빈도의 증가율은 일정한 데 비해, 유형의 증가율은 상대적으로 작기 때문이다.

연구 물음

어휘 다양성으로 18세기 만주어 학습서의 난이도를 잴다.

각주 3이 적어 둔 것

“텍스트의 양이 많아질수록 TTR 값은 작게 수렴한다. 빈도의 증가율은 일정한 데 비해, 유형의 증가율은 상대적으로 작기 때문이다.”

앞에서 본 어휘 성장 곡선을 이 논문은 각주 한 줄로 적어 두었다.

논문이 쓰는 말: “유형”과 “빈도”

정성훈, 도정엽. (2021). 《한글》 82(4), 999–1030.

분석할 것이다. 외국어 교재의 관점에서는 유형/빈도 비율은 주어진 텍스트의 어휘 항목의 난이도(difficulty of lexical items)를 보여줄 수 있는 지표이기도 하기 때문이다. 유형과 빈도 비율이 작다는 것은 똑같은 단어가 여러 차례 반복된다는 것을 의미하고, 반대로 유형과 빈도 비율이 높다는 것은 상대적으로 다양한 단어가 사용되고 있다는 의미로, 학습자들의 어휘 학습에 영향을 주는 중요한 요소들 중의 하나이기 때문이다.

“유형” 타입 빈도

“빈도” 토큰 빈도

“유형과 빈도 비율”이 곧 TTR이다

논문마다 부르는 이름이 다르다. 무엇을 센 값인지를 보고 읽어야 한다.

권별 TTR — 타입은 더해지지 않는다

정성훈, 도정업. (2021). 《한글》 82(4), 999–1030. <표 3>

다음으로 『청어노걸대』 권별로 유형과 빈도 비율을 측정하였다.

권	빈도(<i>n</i>)	유형(<i>N</i>)	유형/빈도 비율(TTR)
1	2,150	418	0.194
2	2,087	499	0.239
3	1,905	460	0.241
4	1,999	435	0.217
5	1,819	405	0.223
6	1,850	431	0.233
7	1,919	638	0.332
8	1,695	397	0.234
전체	15,424	1,409	0.091

<표 3> 『청어노걸대』 각 권별 유형과 빈도 비율

주목할 점

권마다 TTR이 0.194–0.332인데
전체는 0.091로 어느 권보다도
낮다.

까닭

토큰은 더해진다(권별 합 15,424
= 전체). 그러나 타입은 더해지지
않는다(3,683 ≫ 1,409).

권이 바뀌어도 ‘이’, ‘하다’ 같은 말은 다시 나온다. 어휘 성장 곡선이 휘는 이유다.

크기가 비슷하면 TTR도 비슷해진다

코퍼스	토큰	타입	TTR
『청어노걸대』 전체 (18세기 만주어 학습서)	15,424	1,409	0.091
Apicius 레시피 카드 전체 (4세기 로마 요리책)	17,156	1,583	0.0923

주제도 언어도 시대도 다른데 TTR이 소수 둘째 자리까지 같다

두 코퍼스가 공유하는 것은 **크기**뿐이다. 1만 5천 토큰 대 1만 7천 토큰. TTR이 그동안 무엇을 재고 있었는지에 대한 증거다.

다만 이렇게까지 비슷한 것은 우연이다

두 코퍼스는 **토큰화 기준이 서로 다르다**. 한쪽은 형태소, 한쪽은 대문자 단어다. 크기가 비슷하면 TTR도 비슷해지는 **경향**을 보여 줄 뿐, 이 둘을 직접 견준 값으로 읽어서는 안 된다.

권7과 논문의 결론

정성훈, 도정업. (2021). 《한글》 82(4), 999–1030.

다. 그런데 『청어노결대』에서는 빈도도 일정하게 유지되고, 유형의 수도 <권7>을 제외하면 약 400개 내외로 일정하게 유지되고 있다. 따라서 『청어노결대』의 각 권은 숙달도에 따라 구분한 것은 아님을 알 수 있다. 『청어노결대』가 초급/중급/고급 교재인지는 알 수는 없으나, 전체 『청어노결대』는 숙달도가 동일한 학습자가 학습하는 교재임을 확인할 수 있었다. 따라서, 빈도의 차이가 크지 않아서 학습자의 학습량 차이는 권별로 크지 않았던 것으로 보이나, 유형의 수에서는 권별로 학습의 난이도에는 차이가 있는 것으로 보인다. 특히 <권7>의 유형이 많은 것으로 보아 <권7>을 학습할 때 크게 어려움을 겪었을 것으로 추정된다.

권7만 툐다

유형 638, TTR 0.332. 다른 권은 유형 397–499, TTR 0.194–0.241이다.

길이는 튀지 않는다

토큰은 8권 전체에서 **1,695–2,150**으로 고르게 나타난다. 그래서 “권7 학습이 어려웠을 것”이라 말할 수 있다.

견줄 대상의 길이가 고르면 TTR을 그대로 쓸 수 있다. 앞에서 본 TTR의 약점이 여기서는 문제가 되지 않는다.

1 무엇을 세는가

2 어휘 다양성

3 **지프의 법칙**
두 법칙
머리와 꼬리

4 생산성

5 마무리

두 개의 지프 법칙

5강에서 배운 것 — 약어 법칙

자주 쓰이는 말일수록 **짧다**.

- 재는 것: 〈길이 ↔ 평균 빈도〉
- 3글자 37.32회 ... 10글자 2.22회
- 로그를 취한 상관계수 $r = -0.29$

오늘 — 순위-빈도 법칙

빈도 순위와 빈도는 **반비례**한다.

- 재는 것: 〈순위 ↔ 빈도〉
- 1위 AND 1,265회, 2위 THE 1,009회
- 대부분의 단어는 한두 번뿐이다

이름은 같고 재는 것은 다르다

둘 다 George K. Zipf가 정리했고, 둘 다 ‘최소 노력의 원리’로 설명된다. 그러나 **한쪽은 길이를, 한쪽은 순위를** 빈도와 견준다.

순위-빈도 법칙

수식

$$f(r) \approx \frac{C}{r^\alpha}$$

$$\log f(r) = \log C - \alpha \log r$$

로그-로그 축에서 **직선**이 된다.

r 순위(rank)

$f(r)$ 그 순위의 빈도(frequency)

α 기울기. C 는 상수


$\alpha \approx 1$ 이면

2위는 1위의 절반, 3위는 1위의 3분의 1쯤 나온다.

동요 10편			Apicius		
1위	은	16	1위	AND	1,265
2위	가	6	2위	THE	1,009
3위	하늘	5	3위	WITH	726
4위	바람	5	4위	PEPPER	467
5위	로	4	5위	BROTH	400

동요는 5위부터 8위까지 값이 모두 4다. **동점 처리도 적어 두어야 할 결정이다.**

작은 코퍼스에서도 보이는가




185토큰짜리 코퍼스에서도

왼쪽은 급히 떨어지다 바닥에 붙고, 오른쪽 로그-로그에서는 계단꼴 직선이 보인다.

두 수

- 단발어 65개 — 104타입의 62.5%
- 상위 5개 타입이 전체 토큰의 **19.5%**

큰 코퍼스에서



기울기 $\alpha = 1.26$ — 멱법칙(power law)

한 양이 다른 양의 **거듭제곱**에 비례하는 관계다. 로그-로그에서 직선이 되는 까닭이다.

오른쪽 끝의 평평한 계단

빈도가 1인 **단발어 679개**가 만든 것이다. 꼬리에서는 순위가 뜻을 잃는다.

멱법칙에는 **대표값이 없다**. 평균은 10.8회인데 AND는 1,205회, 타입의 42.9%는 1회다.

머리와 꼬리

터미널 입력 — 3강의 파일을 4강의 awk로 더한다

```
head -n 10 data/apicius/word-freq.txt | awk '{s+=$1} END {print s}'  
awk '{s+=$1} END {print s}' data/apicius/word-freq.txt
```

실행 결과

```
5258  
21328
```

머리는 기능어, 꼬리는 내용어

- 상위 10개가 전체 토큰의 **24.7%**를 차지한다.
- 타입 2,434개 중 **단발어**가 **1,118개**(45.9%). **6강의 그 수다.**

꼬리가 두꺼워 코퍼스를 키워도 새 단어가 끝없이 들어온다. 어휘 성장 곡선이 평평해지지 않고 느리지만 꾸준히 증가하는 것도 이 때문이다.

확인 질문

여기까지 정리해 봅시다

- 1 텍스트가 길수록 TTR이 낮아지는 까닭을 ‘타입은 왜 느리게 느는가’로 설명해 보자.
- 2 동요 0.562와 Apicius 0.0923 중 어휘가 더 다양한 쪽은 어디인가?
- 3 STTR을 논문에 적을 때 반드시 함께 적어야 할 것 셋은 무엇인가?
- 4 5강의 약어 법칙과 오늘의 순위-빈도 법칙은 각각 무엇과 무엇의 관계인가?
- 5 로그-로그 축에서 직선이 나온다는 것은 무슨 뜻인가?

1 무엇을 세는가

2 어휘 다양성

3 지프의 법칙

4 **생산성**
생산성이란
재는 법
한국어 사례

5 마무리

그 패턴은 살아 있는가

생산성(productivity)

어떤 형태론적 패턴이 **새 단어를 만들어 내는 능력**.

살아 있는 패턴


- [X-족]: 캥거루족, 오팔족, 덩크족
 - [X-러]: 등산러, 자취러
 - 영어 -ness: happiness, coolness
- 새 어기가 붙어도 바로 알아듣는다.

굳은 패턴

- 영어 -th: warmth, depth, width
*coolth, *slowth
 - [X-보]: 울보, 겁보, 떡보
- 단어의 목록이 있을 뿐 새로 생기지 않는다.

같은 접미사를 쓰는 단어가 사전에 **몇 개 있는지가 아니라, 지금도 새로 생기는지**를 묻는 것이다.

빈도가 높으면 생산적인가



위아래가 생산성을 가른다

- 토큰 빈도 $\neq$ 생산성
- 타입 빈도가 생산성에 가깝다

오른쪽 아래 칸의 실례

Berg의 불규칙 동사다. 토큰은 **56.2%**인데 타입은 163개뿐이고, 새로 생기지 않는다.

자주 쓰인다는 것과 새것을 만든다는 것은 다른 일이다. 오히려 고빈도 패턴이 **화석처럼** 굳기 쉽다.

Baayen의 세 척도

이름	기호	무엇을 나누는가	무엇을 켜다
기생산성	$V(A)$	—	이미 만들어진 것
잠재생산성	$P = V_1(A)/N_A$	그 접사의 토큰으로	앞으로 만들 힘
확장생산성	$P^* = V_1(A)/V_1$	코퍼스 전체 단발어로	새말 시장에서의 몫

A 재려는 접사나 패턴 (예: -ING)

N_A A 가 붙은 말의 **토큰** 수

$V(A)$ A 가 붙은 말의 **타입** 수. 이 값 자체가 기생산성이다

$V_1(A)$ 그 가운데 **단발어**의 수

V_1 코퍼스 **전체**의 단발어 수. Apicius라면 1,118이다

§2에서 코퍼스 전체에 쓰던 N 과 V 에 **접사** A 를 달았을 뿐이다.

R. Harald Baayen. (2009). Corpus linguistics in morphology: morphological productivity.

왜 하필 단발어인가

새말은 거의 반드시 단발어로 나타난다


막 만들어진 단어가 한 코퍼스에서 여러 번 쓰일 일은 드물다. **단발어가 많다는 것은 지금도 새말이 생기고 있다는 뜻이다.**

6강의 1,118개가 여기 쓰인다

그때는 “세어 보니 이렇더라”였고, 오늘은 **측정의 재료다.**

조심할 것

단발어가 다 새말은 아니다. **오타자, 고유명사, OCR 오류도 딱 한 번 나온다.**



Apicius의 접미사를 세어 본다

노트북 입력 — -ING으로 끝나는 단어만 골라 센다

```
import re, collections

w = re.findall(r'[A-Z]{3,}', open('data/apicius/recipes.txt').read())
c = collections.Counter(x for x in w if x.endswith('ING'))
print(sum(c.values()), len(c), sum(v == 1 for v in c.values()))
```

실행 결과

```
274 84 53
```

한 줄에 N_A (토큰), $V(A)$ (타입), $V_1(A)$ (단발어) 셋이 다 나왔다. 이것을 접미사 넷에 돌린 결과가 다음 장이다.

-ED와 -ING

접미사	N_A (토큰)	$V(A)$ (타입)	$V_1(A)$ (단발어)	P	P^*
-ED	1,035	152	60	0.0580	0.0537
-ING	274	84	53	0.1934	0.0474
-LY	214	55	24	0.1121	0.0215
-ION	45	23	14	0.3111	0.0125

오늘의 결론

-ED는 -ING보다 토큰이 **3.78배** 많은데 잠재생산성은 **3.33배** 작다.

앞 프레임의 2×2 가 우리 코퍼스 안에서 그대로 재현되었다

4강부터 다섯 번 다룬 바로 그 파일에서 나온 값이다. -ED는 굳은 낱말로 자주 쓰이고, -ING은 새 어기에 계속 붙는다.

P 와 P^* 는 다른 것을 잰다

둘의 순위가 어긋난다

-ING은 P 가 -ED의 3.33배지만, P^* 는 오히려 -ED가 크다 ($0.0537 > 0.0474$).

분모가 다르기 때문이다

P 의 분모는 **그 접사의 토큰**, P^* 의 분모는 **코퍼스 전체의 단발어**다. P^* 는 접사의 **덩치**를 함께 반영한다.

표본이 작으면 P 가 부풀려진다

-ION은 P 가 0.3111로 가장 크지만 토큰이 **45개**, 타입이 **23개**뿐이다. 45개로 잰 0.31과 1,035개로 잰 0.058을 나란히 놓을 수 있는가?

TTR에 물었던 그 물음이 생산성에도 그대로 온다. N_A 를 **적지 않은 P 는 읽을 수 없다**.

[X-男]과 [X-女]

박수민 (manuscript)

1990-2024년 뉴스 기사 제목에서 뽑은 용례

- 「달빛가족」돌출연기 인기 최루성순종女 밋지않은 허풍 (1990-02-23 동아일보)
- 미모女, 재력男은 애인 있을 확률 높다? (2010-11-22 머니투데이)
- 이런 끈기 代이어 50년간 같은번호 쓴 호주男 결국 로또1등 (2020-08-24 중앙일보)

	N_A (토큰)	$V(A)$ (타입)	$V_1(A)$ (단발어)
[X-男]	44,122	2,954	1,641
[X-女]	38,375	3,326	1,930

Berg의 표와 같은 모양이다

토큰은 男이 많고, 타입과 단발어는 女가 많다. TTR
6.70% 대 **8.67%**, 잠재생산성
3.72% 대 **5.03%**.

사전에 오르면 생산성이 끝난다

박수민 (manuscript)

『표준국어대사전』에 오른 것

- [X-男] 2,954개 타입 중 **5개**: 동거男, 이혼男, 유부男, 열혈男, 동정男
- [X-女] 3,326개 타입 중 **11개**: 동거女, 이혼女, 독신女, 약혼女, 윤락女, 그女 ...

어휘화(lexicalization)

사전에 오른 단어는 **어휘화가 끝난** 단어다. 그때그때 만들어 쓰는 말이 아니라 통째로 외워 쓰는 낱말이 되었다.

타입의 99% 이상이 미등재어다

그래서 등재 여부가 생산성 척도의 재료가 된다. 사전에 없다는 것이 **살아 있다**는 증거다.

김한샘 (2013, 2015)

박수민 (manuscript)

한국어에 맞춘 생산성 공식

$$P_{2013} = (n_1 + 1) \times \frac{T}{N}$$

$$P_{2015} = (n_1 + U + 1) \times \frac{T}{N}$$

- n_1 단발어 수, U 미등재어 종수
- T 파생어 종수(타입 빈도)
- N 평균 빈도 이하 어휘소들의 총 빈도

	n_1	U	T	N
[X-男]	1,641	2,949	2,954	6,368
[X-女]	1,930	3,315	3,326	6,415

	P_{2013}	P_{2015}
[X-男]	761.69	2129.68
[X-女]	1001.17	2719.91
女/男	1.31	1.28

P 는 0과 1 사이인데 이 값은 수백이다. 두 접사의 **상대적인 비교만 유효하다.**

확인 질문

오늘 배운 것을 정리해 봅시다

- 1 7강 마지막의 ANOTHER 116은 세 가지 빈도 중 무엇인가?
- 2 P 와 P^* 의 분모는 각각 무엇인가?
- 3 -ED는 토큰이 3.78배 많은데 왜 덜 생산적인가?
- 4 “단발어가 많으니 생산적이다”라고 말할 때 조심할 점 둘은 무엇인가?
- 5 [X-男]이 토큰은 많은데 생산성이 낮은 것을 Berg의 표와 견주어 말해 보자.

1 무엇을 세는가

2 어휘 다양성

3 지프의 법칙

4 생산성

5 마무리

요약

심화 과제

다음 시간

오늘 배운 것

세 가지 빈도

- 토큰·타입·문서 빈도는 서로 다른 수다
- 바람 5/1 대 산 3/3 — 순위가 뒤집힌다
- `grep`와 `grep -l`은 다른 것을 센다

어휘 다양성

- TTR은 길이를 잔다 ($0.54 \rightarrow 0.09$)
- STTR은 구간 길이와 함께 적는다
- 타입은 더해지지 않는다

지프

- 순위-빈도 법칙 $\alpha = 1.26$
- 5강의 약어 법칙과 재는 것이 다르다
- 머리 10개 24.7%, 꼬리 단발어 45.9%

생산성

- -ED는 토큰 3.78배, 생산성 3분의 1
- 단발어가 새말의 지표가 된다
- 男은 토큰이, 女는 타입이 많다

보고할 때 적어야 할 것

빈도 토큰·타입·문서 중 무엇인지, 그리고 **세는 단위**(단어? 형태소? 부분 문자열?)

TTR 토큰 수 N 을 반드시 함께. N 없는 TTR은 읽을 수 없다

STTR 구간 길이, 구간 수, 자투리를 어떻게 했는지

생산성 어떤 코퍼스에서, 어떤 척도로, N_A 가 얼마일 때의 값인지

코드 세는 데 쓴 명령과 스크립트를 저장소에 남긴다

오늘 본 논문들이 보여 준 것

같은 ‘빈도’라는 말이 논문마다 다른 것을 가리켰다. 타입 빈도를 “유형”이라 부른 곳도 있었고, 문서 빈도를 “게시글 수”라 한 곳도 있었다.

수를 적는 것만으로는 모자란다. **그 수가 무엇을 센 것인지**까지 적어야 남이 다시 만들어 낼 수 있다.

[숙제00심화] 논문의 통계량·시각화 재검토

할 일 (선택)

이 강의에서 배운 내용을 토대로, 언어학 논문을 읽다가 통계량 계산이나 시각화 방법에서 개선할 수 있는 점을 찾으면 eTL **심화과제 게시판**에 공개글로 올린다.

게시물에 적을 것

- 1 논문의 서지사항(URL까지)
- 2 개선의 여지가 있는 부분(쪽수, 표·그림 번호까지)
- 3 개선 방안

1건당 **0.5점**, 최대 **2점**(4건)까지 **과제 점수**를 보충한다. 강의 자료나 먼저 올라온 글과 겹치면 인정하지 않는다. 작성 방법과 예시는 문제지 hw00adv-problems.pdf에 있다.

다음 시간에 배울 것 (9월 30일 수요일)

제9강 문자 인코딩과 유니코드

오늘은 “무엇을 하나로 셀 것인가”를 물었다. 다음 시간은 한 칸 더 내려가 **글자 하나가 무엇인가**를 묻는다. ‘바람’의 길이를 썼더니 2가 아니라 6이 나오는 까닭이다.

ANOTHER 116의 답

`value_counts()`는 행을 센다. 그 표의 한 행은 레시피 한 편이었다. 그러니 116은 제목이 **ANOTHER**로 시작하는 레시피 **116편** — 문서 빈도다.

과제 안내

[숙제04] **seaborn** 연습 마감은 **2026-10-02 12:00 (금요일 정오)**. [숙제00심화]는 **2026-12-18 09:00 (금요일 오전 9시)**까지 언제든지 올리면 된다.