2026학년도 2학기 언어데이터과학

제13강 모두의 말뭉치 (3) ‘완전’과 ‘아주’의 연령별·성별 용례 비교

박수민

서울대학교 인문대학 언어학과

2026년 10월 21일 수요일

지난 시간에 배운 것

1. 논문의 물음을 **무엇을 어떻게 세는가**로 바꾸어 적었다(조작적 정의).
2. \b로 낱말을, Kiwi로 바로 뒤 형태소를 찾아 품사별 비율로 비교했다.
3. 명사 앞은 '완전', 부사 앞은 '아주'였다. 수는 경향을 보여 줄 뿐이다.

오늘의 목표

1. 화자 표의 한 행이 무엇을 세는지 따져 볼 수 있다.
2. 두 표를 열쇠 두 개로 이어 붙일 수 있다.
3. 크기가 다른 집단을 비율로 비교할 수 있다.
4. 그 비율이 몇 사람에게서 나왔는지 확인할 수 있다.

사전 준비

터미널 입력

```
cd /workspaces/LDS2026
```

11강의 CSV 두 개를 쓴다. 없으면 11강 노트북부터 [Run All]로 돌린다. 오늘은 Kiwi를 쓰지 않는다.

노트북 13-age-sex.ipynb의 첫 셀

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

sns.set_theme(style='whitegrid', font='NanumGothic')
```

1 누가 말했나
화자 표
168,267은 사람 수인가
열쇠 두 개

2 나이로, 성별로

3 몇 사람의 말인가

4 용례와 해석

5 마무리

화자 표를 다시 읽는다

노트북 입력

```
sp = pd.read_csv('data/nikl/speakers.csv')
print(sp.shape)
print(sp['age'].value_counts().to_dict())
print(sp['sex'].value_counts().to_dict())
```

실행 결과

```
(168267, 10)
{'20대': 78318, '30대': 61229, '40대 이상': 18474, '10대': 10246}
{'여성': 147252, '남성': 21015}
```

11강에서 남긴 화자 표다. 오늘은 이름을 줄여 sp라고 부른다. 나이는 네 구간으로, 성별은 둘로 적혀 있다. **고르게 모이지 않았다.** 20대가 46.5%, 여성이 87.5%이고, 10대와 40대 이상은 합쳐도 17%다.

나이와 성별을 함께

노트북 입력

```
print(pd.crosstab(sp['age'], sp['sex'], margins=True))
```

실행 결과

sex	남성	여성	All
age			
10대	752	9494	10246
20대	7514	70804	78318
30대	9757	51472	61229
40대 이상	2992	15482	18474
All	21015	147252	168267

margins 행과 열의 합(All)을 덧붙인다

남성은 어느 나이에서나 적다. 10대 남성은 752행으로, 10대의 7.3%다. 40대 이상에서는 16.2%다. **남성은 나이 든 쪽에 조금 더 몰려 있다.** 오늘 내내 이 표를 옆에 둔다.

속성이 모두 같은 화자

노트북 입력

```
cols = ['age', 'occupation', 'sex', 'birthplace',
        'principal_residence', 'current_residence', 'device', 'keyboard']
sp['who'] = sp.groupby(cols).ngroup()
print(sp['who'].nunique())
print(sp['who'].value_counts().head(3))
```

실행 결과

```
2108
who
1006    3219
902     2177
1560    1800
Name: count, dtype: int64
```

ngroup은 묶음마다 0부터 번호를 매겨 행마다 돌려준다. 속성 여덟 칸이 모두 같은 화자는 같은 번호 who를 받았다. 168,267행이 2,108가지뿐이다. 1006번(20대 학생 여성, 서울, 스마트폰, 쿼티)은 3,219행이다. 3,219명일까, 몇 사람이 여러 번 나온 것일까? **이것만으로는 모른다.**

같은 짝이 692번

노트북 입력 — 2인 대화(MD로 시작하는 파일, 11강)만

```
md = sp[sp['doc_id'].str.startswith('MD')]
pairs = md.groupby('doc_id')['who'].agg(['min', 'max'])
print(len(pairs))
print(pairs.value_counts().head(3))
```

실행 결과

```
62491
min   max
1779  1962    692
462   1006    585
568   641     525
Name: count, dtype: int64
```

agg 셈 여러 개를 한 번에 한다. 여기서는 대화마다 두 화자 번호의 작은 것과 큰 것

작은 것과 큰 것으로 적으면 누가 1번 화자였든 같은 짝이 된다. 2인 대화 62,491건 가운데 692건이 1779번과 1962번의 대화다.

1779번과 1962번

노트북 입력

```
two = sp[sp['who'].isin([1779, 1962])]
print(two.set_index('who')[cols].drop_duplicates().T)
```

실행 결과

who	1779	1962
age	40대 이상	40대 이상
occupation	가정 주부	사무 종사자
sex	여성	남성
birthplace	경기	경기
principal_residence	인천	인천
current_residence	경기	경기
device	스마트폰	스마트폰
keyboard	2벌식(쿼티)	2벌식(쿼티)

.T는 행과 열을 뒤바꾼다. 열이 많은 행 둘을 세로로 세워 비교한다.

40대 이상의 여성과 남성이다. 나고, 오래 살고, 지금 사는 곳이 같고, 기기와 자판도 같다. **같은 두 사람이 692번 대화했다**고 보는 편이 자연스럽다.

화자 표의 한 행은 무엇인가

한 행은 '대화 하나 속의 화자 하나'다

같은 사람이 대화를 여러 번 보내면 그때마다 행이 새로 생긴다. 말뭉치는 개인 정보를 지우면서 사람에게 번호를 주지 않았다. 그래서 168,267은 **사람 수가 아니다**. 여성 87.5%도 사람의 비율이 아니라 '대화 속 화자'의 비율이다.

who는 사람의 조작적 정의다

속성 여덟 칸이 모두 같으면 같은 사람으로 친다. 12강의 품사 묶음처럼, 정하고 적어 둔다.

- 너무 많이 묶을 수 있다. 서울의 20대 여학생은 아마 여럿이다
- 너무 적게 묶을 수 있다. 같은 사람도 기기를 바꾸거나 나이 구간을 넘으면 둘이 된다

그래도 **한 사람이 수를 얼마나 끌고 가는지**는 가늠할 수 있다(§3).

발화마다 화자를 찾아 붙인다

u (2,977,840행)

doc_id	speaker_id	form
…02.1	2	하이하이
…02.1	1	반가워욬ㅌㅋㅋ
…02.1	1	name2님 제 이상형은

sp (168,267행)

doc_id	speaker_id	age	sex	who
…02.1	1	20대	여성	644
…02.1	2	20대	여성	792

7강의 merge를 열쇠 두 개로

7강에서는 레시피 번호 number 하나로 권 이름을 붙였다. 오늘은 doc_id와 speaker_id가 **둘 다** 같은 행끼리 짝짓는다(11강의 '열쇠는 두 열'). 발화 여럿이 화자 하나를 가리키므로 여럿 대 하나(many-to-one)의 잇기다.

11강에서 표를 둘로 나눈 까닭이 이것이었다. 나이와 성별은 필요할 때 찾아 붙인다.

merge — 열쇠 두 개로 잇기

노트북 입력

```
u = pd.read_csv('data/nikl/utterances.csv')
u = u.merge(sp[['doc_id', 'speaker_id', 'age', 'sex', 'who']],
            on=['doc_id', 'speaker_id'], how='left',
            validate='many_to_one')
print(u.shape)
print(u['age'].isna().sum())
```

실행 결과

```
(2977840, 9)
0
```

on 열쇠 열의 목록. 모두 같아야 짝이 된다

how `'left'`면 왼쪽(발화) 행을 짝이 없어도 남긴다

validate 오른쪽 열쇠가 겹치지 않는지 확인하고, 겹치면 멈춘다

행 수가 그대로이고 age의 NaN이 0이다. **모든 발화가 화자를 하나씩 찾았다.**

열쇠가 하나뿐이면

노트북 입력 — 일부러 틀린 줄. 노트북에는 넣지 않는다

```
u.merge(sp, on='speaker_id', validate='many_to_one')
```

실행 결과 — 오류 메시지의 첫 줄

```
MergeError: Merge keys are not unique in right dataset; not a many-to-one merge
```

validate가 없었다면

1번 화자의 발화 1,418,839개가 화자 표의 '1번 화자' 74,665행 모두와 짝지어진다. 모두 합하면 **약 2,101억 행**이다. 멈추지 않고 메모리를 다 쓴 뒤에야 커널이 죽는다.

validate는 **내가 생각한 짜임**을 코드로 적어 두는 것이다. 틀리면 조용히 넘어가지 않는다.

1 누가 말했나

2 **나이로, 성별로**
세고 나누기
성별

3 몇 사람의 말인가

4 용례와 해석

5 마무리

발화마다 세어 둔다

노트북 입력

```
for w in ['완전', '아주']:
    u[w] = u['form'].str.count(rf'\b{w}\b')
print(u[['완전', '아주']].sum())
```

실행 결과

```
완전    8636
아주    3397
dtype: int64
```

12강의 \b 셈 그대로

12강에서는 `.sum()`으로 바로 더해 수 하나를 얻었다. 오늘은 발화마다의 횟수를 **열로 남겨 둔다**. 그래야 나이와 성별로 나누어 더할 수 있다.

붙여 쓴 '완전좋아'는 놓치지만(12강) Kiwi 없이 빠르게 센다. 형태소로 세어도 뒤에 나올 나이별 '완전'의 몫은 2%p 안쪽에서 같다.

나이마다 더한다

노트북 입력

```
age = u.groupby('age')[['완전', '아주']].sum()
age['발화'] = u.groupby('age').size()
print(age)
```

실행 결과

age	완전	아주	발화
10대	589	60	109608
20대	5062	1772	1593040
30대	2296	1101	1024097
40대 이상	689	464	251095

`size()` 묶음마다의 행 수. 여기서는 발화 수다

20대의 '완전'이 5,062번으로 가장 많다. 그런데 20대는 발화도 159만 개로 가장 많다. **많이 말한 집단이 많이 쓴다.** 모두가 다른 집단은 개수 그대로 비교할 수 없다(12강).

만 발화당 몇 번

노트북 입력

```
rate = age[['완전', '아주']].div(age['발화'], axis=0) * 10000
print(rate.round(1))
```

실행 결과

age	완전	아주
10대	53.7	5.5
20대	31.8	11.1
30대	22.4	10.8
40대 이상	27.4	18.5

`div` 나누기. 두 열을 같은 Series로 나눈다

`axis=0` 나이를 맞추어 행마다 그 행의 발화 수로 나눈다

'아주'는 나이가 많을수록 잦다(5.5 → 18.5). '완전'은 10대가 가장 잦지만 40대 이상이 30대보다 잦다. **한 줄로 늘어서지 않는다.**

둘 가운데 무엇을 고르나

노트북 입력

```
def share(t):
    return t['완전'] / (t['완전'] + t['아주']) * 100

age['완전%'] = share(age)
print(age['완전%'].round(1))
```

실행 결과

```
age
10대       90.8
20대       74.1
30대       67.6
40대 이상    59.8
Name: 완전%, dtype: float64
```

'완전'의 몫

'완전'과 '아주'를 합한 것 가운데 '완전'이 차지하는 비율이다. 10대 90.8에서 40대 이상 59.8까지 **나이가 많을수록 줄어든다**. 식을 함수로 적어 두었으니 뒤의 표에도 그대로 쓴다.

두 잣대는 다른 것을 묻는다

	만 발화당 수	‘완전’의 몫
나누는 수	발화 수	‘완전’ + ‘아주’
묻는 것	얼마나 자주 쓰나	둘 가운데 무엇을 고르나
함께 흔들리는 것	말수, 주제, 강조를 얼마나 하나	두 낱말 밖의 일에는 덜 흔들린다

변이형(variant)

‘완전 좋아’와 ‘아주 좋아’처럼 같은 자리에서 고를 수 있는 말들이다. 사회언어학은 흔히 **변이형 사이의 몫**을 센다. 엄밀히는 둘 다 올 수 있는 자리만 세야 한다. 12강의 명사 앞은 거의 ‘완전’의 자리였다.

성별로

노트북 입력

```
sex = u.groupby('sex')[['완전', '아주']].sum()
sex['완전%'] = share(sex)
print(sex.round(1))
```

실행 결과

sex	완전	아주	완전%
남성	879	455	65.9
여성	7757	2942	72.5

여성 쪽이 '완전'을 6.6%p 더 고른다. 그런데 '완전'과 '아주'를 합해 남성은 1,334번, 여성은 10,699번이다. 남성 쪽 수는 여덟 배 작은 바탕에서 나왔다. **작은 쪽을 더 잘게 나누면** 어떻게 될까?

나이와 성별을 함께

노트북 입력

```
both = u.groupby(['age', 'sex'])[['완전', '아주']].sum()
both['완전%'] = share(both)
print(both.unstack().round(1))
```

실행 결과

	완전		아주		완전%	
sex	남성	여성	남성	여성	남성	여성
age						
10대	37	552	1	59	97.4	90.3
20대	566	4496	245	1527	69.8	74.6
30대	188	2108	126	975	59.9	68.4
40대 이상	88	601	83	381	51.5	61.2

unstack은 안쪽 색인(sex)을 열로 올려 남녀를 나란히 세운다.

칸이 작으면 비율이 흔들린다

10대 남성의 '아주'는 1번이다. 한 번만 더 나왔어도 97.4는 94.9가 된다.

섞인 집단을 나누어 본다

5강의 교란변수

남성은 나이 든 쪽에 조금 더 몰려 있고(10대의 7.3%, 40대 이상의 16.2%), 나이가 많을수록 '완전'의 몫이 작다. 그러면 남성의 몫이 작은 것은 **나이 탓**일 수도 있다. 5강의 후추와 버클리처럼, 섞인 집단은 나누어 본다.

'완전'의 몫 (%)	전체	10대	20대	30대	40대 이상
여성	72.5	90.3	74.6	68.4	61.2
남성	65.9	97.4	69.8	59.9	51.5
차이	6.6	−7.1	4.8	8.5	9.7

나이 안에서 비교해도 차이가 줄지 않는다. 나이만으로는 설명되지 않는다. 그런데 남성 쪽 수는 **몇 사람에게서** 나왔을까?

확인 질문

표를 잇고 나누며

1. 화자 표의 168,267행을 '화자 168,267명'이라고 읽으면 안 되는 까닭은?
2. `merge`에 `how='left'`와 `validate='many_to_one'`을 준 까닭을 각각 말해 보자.
3. 20대의 '완전'이 5,062번으로 가장 많다. 20대가 '완전'을 가장 즐겨 쓴다고 말할 수 있는가?
4. 만 발화당 '완전'은 40대 이상이 30대보다 잦은데, '완전'의 몫은 40대 이상이 더 작다. 어떻게 둘 다 참일 수 있는가?

1 누가 말했나

2 나이로, 성별로

3 **몇 사람의 말인가**
한 사람이 끄는 수
사람마다 한 표

4 용례와 해석

5 마무리

20대 남성의 '완전' 566번

노트북 입력

```
m = u[(u['age'] == '20대') & (u['sex'] == '남성')]
top = m.groupby('who')['완전'].sum().sort_values(ascending=False)
print(top.head(3))
print(top.sum(), (top > 0).sum())
```

실행 결과

```
who
825    347
885     35
543     33
Name: 완전, dtype: int64
566 44
```

566번 가운데 347번이 한 사람

20대 남성 가운데 '완전'을 한 번이라도 쓴 사람(who)은 44명이다. 그 가운데 825번 한 사람이 61%를 썼다. 두 번째 사람은 35번이다.

`(top > 0).sum()`은 참의 개수, 곧 '완전'을 쓴 사람 수다(6강의 마스크 셈).

그 사람의 대화

노트북 입력

```
x = u[u['who'] == top.index[0]]
print(x.groupby('doc_id')['완전'].sum().nlargest(4))
print(x['doc_id'].nunique(), len(x))
```

실행 결과

```
doc_id
MDRW2100001609.1    98
MDRW2100047114.1    90
MDRW2100001612.1    83
MDRW2100001611.1    69
Name: 완전, dtype: int64
60 33989
```

`nlargest(4)`는 큰 것부터 넷이다. 825번은 대화 60건에서 발화 33,989개를 보냈다(20대 남성 발화의 18%). '완전'은 그 가운데 대화 네 건에 몰려 있다(340번).

8강의 THYME과 PEAS

34편에 흩어진 말과 14편에 몰린 말은 다르다.
오늘은 문서 자리에 **사람**을 놓는다.

사람마다 몫을 내고 평균한다

노트북 입력

```
p = u.groupby(['who', 'age', 'sex'])[['완전', '아주']].sum()
p = p[p['완전'] + p['아주'] > 0]
p['완전%'] = share(p)
print(len(p), p.groupby('sex').size().to_dict())
print(p.groupby('age')['완전%'].mean().round(1).to_dict())
print(p.groupby('sex')['완전%'].mean().round(1).to_dict())
```

실행 결과

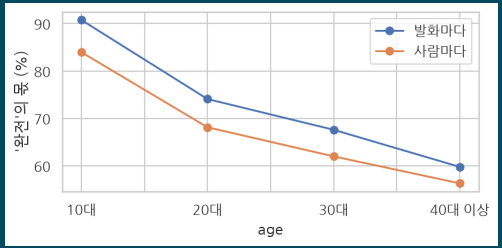
```
1014 {'남성': 160, '여성': 854}
{'10대': 84.0, '20대': 68.1, '30대': 62.0, '40대 이상': 56.3}
{'남성': 57.5, '여성': 67.5}
```

347번 쓴 사람도 **한 표**다. 그래도 순서는 그대로다. 다만 남성은 160명뿐이다.

두 셈을 한 그림에

노트북 입력

```
cmp = pd.DataFrame({'발화마다': age['완전%'],
                    '사람마다': p.groupby('age')['완전%'].mean()})
cmp.plot(marker='o', figsize=(6, 2.6), ylabel="'완전'의 몫 (%)")
plt.savefig('plots/wanjeon-age.png', dpi=150, bbox_inches='tight')
```



12강처럼 '열 이름: Series'의 dict로 표를 만들었다. 나이가 같은 행끼리 붙는다. 표의 plot은 열마다 꺾은선을 하나씩 긋는다. 사람마다 한 표로 세면 몫이 3.5–6.8%p 낮아지지만 **기울기는 같다**.

1 누가 말했나

2 나이로, 성별로

3 몇 사람의 말인가

4 **용례와 해석**
수 뒤의 발화
왜 그럴까
저장소에 남기기

5 마무리

10대의 '아주'

노트북 입력

```
def show(a, w):
    s = u.loc[(u['age'] == a) & (u[w] > 0), 'form']
    for f in s.sample(4, random_state=0):
        print(f)
show('10대', '아주')
```

실행 결과

```
아주 조금씩 배우고 있...습니다
그니까 띵동와플 있을 땐 아주 좋았는데...
아주 코미디야
호텔델루나는 저는 안 봤지만 친구가 아주 좋아해서 이름은 알고 있습니다. 그 귀신 쉬면서 성불 도와주는
↪  걸로 알고있어요. 아이유님 나오시고.
```

sample은 무작위로 고르고, random_state를 정해 두면 누가 돌려도 같은 넷이 나온다.

40대 이상의 '아주'

노트북 입력

```
show('40대 이상', '아주')
```

실행 결과

```
뱃속이 아주~ 야물딱지네
ㅋㅋㅋ 전방 15도 아주 세세하게 ㅋㅋ
이햐 에브리봇은 아주 쭉쭉 빠진다 ㅋㅋㅋ
name25이도 아주 괜찮다고 하네.
```

같은 '아주'인데 결이 다르다

10대의 넷 가운데 둘에 격식체 '-습니다'가 있고, 40대 이상은 넷 다 반말이다. 넷으로 말할 수는 없지만 **세어 볼 물음**이 생겼다. 격식을 차린 말에서는 '아주'를 더 고르는가?

세어 본다 — '습니다'가 든 발화

노트북 입력

```
u['습니다'] = u['form'].str.contains('습니다')
f = u.groupby('습니다')[['완전', '아주']].sum()
f['완전%'] = share(f)
print(f.round(1))
```

실행 결과

습니다	완전	아주	완전%
False	8613	3331	72.1
True	23	66	25.8

'습니다'가 든 발화에서 '완전'의 몫은 25.8%, 나머지에서는 72.1%다. share를 다시 썼다.

그러나 89번뿐이다

게다가 '습니다'로는 '합니다', '입니다'를 못 찾는다. ㅂ이 음절 안에 있기 때문이다(9강). 격식체를 무엇으로 찾을지부터 정해야 한다.

나이 차이를 시간으로 읽는다면

2021년의 나이	10대	20대	30대	40대 이상
대략 태어난 때	2000년대	1990년대	1980년대	1970년대 이전
‘완전’의 몫 (%)	90.8	74.1	67.6	59.8

겉보기 시간(apparent time)

한 시점의 나이 차이를 시간에 따른 변화의 흔적으로 읽는 방법이다. 젊을수록 새 말을 많이 쓰면 변화가 진행 중이라고 본다. 김다미(2021)는 very의 ‘완전’이 활발해진 때를 1990년대 중후반 또는 2000년대 초로 보았다(464쪽). 그 뒤에 자란 세대일수록 ‘완전’을 더 고른다.

다른 읽기도 있다

사람이 나이가 들면서 강조 부사를 바꾸는 것일 수도 있다(연령 단계, age grading). 2021년 한 해의 말뭉치로는 **두 읽기를 가를 수 없다**. 다른 해의 말뭉치와 비교해야 한다.

강조 부사는 닳는다

자주 쓰면 힘이 빠진다

자주 쓰인 강조 부사는 뜻이 추상화되어 힘이 빠지고, 더 센 새 말이 그 자리에 든다. 김다미(2021)도 '완전'이 의미의 추상화를 겪고 있다고 보았다(453쪽 각주 11).

12강의 수로 보면

'아주'는 '아주 조금', '아주 가끔'까지 꾸미는, 정도만 남은 닳은 쪽이다. '완전'은 '똑같다', '다르다'와 어울리는 '모두, 두루'가 아직 남은 센 말이다. 젊은 층의 '완전'은 **강조 부사가 바뀌는 흐름**으로도 읽힌다.

영어에서도

Ito & Tagliamonte (2003), *Language in Society* 32(2), 257–279

*very*는 나이 든 화자에서만 가장 흔하고, *really*는 가장 젊은 세대에서 크게 늘었다. 옛 강조 부사는 사라지지 않고 새것과 함께 쓰인다.

여성 쪽이 '완전'을 더 고르는 까닭

노트북 입력 — 두 낱말을 합해 만 발화당

```
n = u.groupby(['age', 'sex']).size()
both['만 발화당'] = (both['완전'] + both['아주']) / n * 10000
print(both['만 발화당'].unstack().round(1))
```

실행 결과

sex	남성	여성
age		
10대	41.2	60.9
20대	43.1	42.9
30대	16.7	36.9
40대 이상	46.9	45.7

변화를 이끈다 지금까지의 연구에서 여성은 대체로 언어 변화를 앞서 이끌었다(Labov 1990)

강조를 더 한다 사적인 말에서는 여성이 강조 부사를 더 썼다(김혜영 · 강범모 2010)

오늘의 수로는 20대와 40대 이상에서 강조를 **얼마나** 하는지가 남녀 거의 같다. 그래도 두 나이 모두 '완전'의 몫은 여성 쪽이 크다. 차이는 **무엇을** 고르는가에 있다.

Labov (1990), *Language Variation and Change* 2(2), 205–254. 김혜영 · 강범모 (2010), 《한국어학》 48, 101–129.

말투를 맞추어 보면

노트북 입력 — 앞에서 만든 '습니다' 열을 다시 쓴다

```
print(u.groupby('sex')['습니다'].mean().round(4).to_dict())
v = u[~u['습니다']]
print(share(v.groupby('age')[['완전', '아주']].sum()).round(1).to_dict())
print(share(v.groupby('sex')[['완전', '아주']].sum()).round(1).to_dict())
```

실행 결과

```
{'남성': 0.0068, '여성': 0.0032}
{'10대': 91.3, '20대': 74.4, '30대': 67.9, '40대 이상': 60.3}
{'남성': 66.6, '여성': 72.8}
```

참·거짓 열의 `mean()`은 참의 비율이고, `~`는 참과 거짓을 뒤집는다. 남성의 발화에는 '습니다'가 두 배 잦고, 격식체에서는 '아주'를 고른다. 그러나 '습니다' 발화를 빼도 **나이와 성별의 순서는 그대로**다. 다만 '습니다'는 격식체의 일부만 잡는다.

다른 말뭉치로 확인하기

교수자가 **일상 대화 말뭉치 2025**의 사적 대화 2,288건(화자 1,712명)을 같은 셈으로 세었다.

	온라인 대화 2021 (메신저)	일상 대화 2025 (녹음 전사)
사람	who로 어림	화자 번호가 사람마다 하나
나이별 '완전'의 몫	90.8 → 59.8 (10대 → 40대 이상)	71.2 → 5.2 (10대 → 60대 이상)
사람마다 한 표로	84.0 → 56.3	68.7 → 7.8
성별 (여성 / 남성)	72.5 / 65.9	24.9 / 16.6
'습니다'가 든 발화	25.8	4.5

방향은 같고, 수준은 다르다

20대만 보아도 74.1 대 47.9다. 2025년 대화는 절반 남짓이 처음 만난 사이로 보이고(몫 22.2, 친구 사이는 61.2) 매체도 달라서, 이 둘로는 **변화와 나이 듦을 가를 수 없다**.

출처: 국립국어원 일상 대화 말뭉치 2025(버전 1.0), https://kli.korean.go.kr/corpus.

해석을 가르려면

해석	오늘의 수	가르려면
변화가 진행 중	사람마다 세어도 젊을수록 몫이 크다	다른 해의 말뭉치를 같은 방법으로
나이 들며 바꾼다	위와 같은 수로도 설명된다	같은 사람들을 여러 해 따라가기
강조 부사의 교체	‘아주 조금’, ‘아주 가끔’(12강)	뜻의 세기를 따로 재기
여성이 변화를 이끈다	나이 안에서도 여성 쪽 몫이 크다	남성이 넉넉한 말뭉치
말투의 차이	‘습니다’를 빼도 순서가 같다	상대와 친밀도를 맞춘 비교

해석은 가설이다

같은 수가 여러 해석과 함께 맞을 수 있다. 하나를 고르기보다 **무엇을 세면 가를 수 있는지**를 적어 둔다. 기말 프로젝트의 물음은 흔히 이런 자리에서 나온다.

이 수가 말하지 않는 것

누구의 말뭉치 모집에 응한 사람들의 대화다. 남성과 10대는 적고, 같은 사람이 여러 번 나온다

사람 who는 속성으로 어림한 사람이다. 실제로는 더 많거나 적을 수 있다

자리 '완전'과 '아주'가 둘 다 올 수 있는 자리만 센 것이 아니다

그래서 보고서에는

12강에 적은 것(말뭉치, 찾은 방법)에 더해, 무엇을 열쇠로 이었는지, 무엇을 사람으로 쳤는지(who), 무엇으로 나누었는지(발화 수, 두 낱말의 합), 칸마다 몇 번이었는지를 적는다.

무엇을 남길까

터미널 입력 — 노트북이 목록에 없으면 Ctrl+S로 저장부터 한다

```
cd /workspaces/LDS2026
git status
```

실행 결과

```
On branch main
Your branch is up to date with 'origin/main'.

Untracked files:
  (use "git add <file>..." to include in what will be committed)
        13-age-sex.ipynb
        plots/wanjeon-age.png

nothing added to commit but untracked files present (use "git add" to track)
```

커밋하기

터미널 입력

```
git add 13-age-sex.ipynb plots/
git commit -m "13강 실습 노트북과 꺾은선그림"
```

실행 결과

```
[main a1b2c3d] 13강 실습 노트북과 꺾은선그림
 2 files changed, 777 insertions(+)
 create mode 100644 13-age-sex.ipynb
 create mode 100644 plots/wanjeon-age.png
```

777줄이 모두 노트북이다. PNG는 세지 않는다. 11강의 CSV는 `data/` 아래라 올라가지 않는다.

푸시하기

터미널 입력

```
git push
```

실행 결과

```
Enumerating objects: 7, done.
Writing objects: 100% (5/5), 67.86 KiB | 22.62 MiB/s, done.
To https://github.com/your-username/LDS2026.git
   e4f5a6b..a1b2c3d  main -> main
```

누가 썼는지도 방법의 일부다

잇기, 세기, 나누기, 사람마다 다시 세기. 무엇을 사람으로 쳤는지까지 노트북에 코드로 남았다. 말뭉치를 받은 사람은 누구나 [Run All]로 같은 표와 그림을 얻는다.

1 누가 말했나

2 나이로, 성별로

3 몇 사람의 말인가

4 용례와 해석

5 **마무리**
- 요약
- 다음 시간
- 과제

오늘 쓴 것

하는 일	오늘의 코드
두 열의 교차표와 합	`pd.crosstab(…, margins=True)`
묶음마다 번호	`sp.groupby(cols).ngroup()`
열쇠 두 개로 잇기	`u.merge(…, on=['doc_id', 'speaker_id'])`
발화마다의 횟수를 열로	`u[w] = u['form'].str.count(rf'\b{w}\b')`
묶음마다 합과 행 수	`u.groupby('age')[[…]].sum(),.size()`
행마다 나누기	`age[[…]].div(age['발화'], axis=0)`
같은 식을 여러 표에	`def share(t): …`
여러 셈을 한 번에	`.agg(['min', 'max'])`
안쪽 색인을 열로	`both.unstack()`
열마다 꺾은선	`cmp.plot(marker='o')`
참과 거짓 뒤집기	`u[~u['습니다']]`

새로 배운 것은 `margins`, `ngroup`, `validate`, `div`, `agg`, `unstack`, `~`이다. 나머지는 7–12강의 도구 그대로다.

오늘 배운 것

화자 표

- 한 행은 대화 속 화자 하나다
- 168,267은 사람 수가 아니다
- 사람도 조작적으로 정의한다

표 잇기

- 열쇠는 두 열을 함께
- `how='left'`로 발화를 모두 남긴다
- `validate`로 짜임을 확인한다

나이와 성별

- 젊을수록, 여성일수록 '완전'을 고른다
- 강조 부사는 닳고 새 말로 바뀐다
- 해석은 가설이다. 가를 자료를 적는다

수를 읽을 때

- 무엇으로 나누었는지 밝힌다
- 작은 칸의 비율은 흔들린다
- 몇 사람의 말인지 확인한다

확인 질문

오늘 것을 정리해 봅시다

1. 7강의 `merge(bk, on='number')`와 오늘의 `merge`는 무엇이 다른가?
2. 성별 '완전'의 몫(72.5 대 65.9)을 보고할 때 함께 적어야 할 수를 둘 들어 보자.
3. 20대 남성의 '완전' 566번 가운데 347번이 한 사람에게서 나왔다. 사람마다 한 표로 세면 무엇이 달라지는가?
4. 젊을수록, 여성일수록 '완전'의 몫이 크다. 해석을 둘 들고, 각각을 가르려면 무엇을 세어야 하는지 말해 보자.
5. '합니다', '입니다'까지 격식체로 세려면 12강의 Kiwi를 어떻게 쓸 수 있을까?

다음 주 (10월 26일 월요일, 28일 수요일)

언어데이터 관리 사례 발표 (1), (2) — 동영상으로

[숙제08]로 낸 자료로 맡은 장을 발표하는 15분 분량의 동영상을 만들어 **10월 28일 수요일 12:00**까지 eTL에 링크를 낸다. 그 주 동안 자신에게 배정된 동영상 4개를 보고 퀴즈를 푼다([숙제09]).

제14강 (11월 2일 월요일) 표준국어대사전 데이터 활용 (1) XML 파일 처리

JSON 다음은 XML이다. 12강에서 웹 화면으로 찾아본 표준국어대사전을 이번에는 데이터 파일로 읽는다.

미리 생각해 둘 것

오늘처럼 말뭉치에서 셀 수 있는 물음을 하나 떠올려 두자. 누가, 무엇 앞에서, 얼마나 쓰는가. [숙제10] 기말프로젝트 주제 선정의 씨앗이 된다.

과제 안내

[숙제08] 언어데이터 관리 사례 조사 [발표]

마감 **2026-10-23 12:00 (금요일 정오)**. 11강에서 안내한 과제다. 부교재에서 맡은 장을 요약한 발표 자료를 `00-presentation.pdf`로 eTL에 낸다(`00`은 맡은 장의 번호).

- 발표 자료에 **퀴즈 문제 하나**를 넣고, 그 정답은 eTL의 입력란에 직접 쓴다
- 연장 신청과 질문은 **내일, 10월 22일 목요일 12:00**까지 받는다

그다음 마감

10월 28일 (수) 12:00 발표 동영상(15분)의 링크를 eTL에 낸다

10월 30일 (금) 12:00 [숙제10] 기말프로젝트 주제 선정

11월 2일 (월) 09:00 [숙제09] 배정된 동영상 4개를 보고 퀴즈를 푼다. **연장 없음**