2026학년도 2학기 언어데이터과학

제15강 표준국어대사전 데이터 활용 (2) 표제어 추출 및 분석

박수민

서울대학교 인문대학 언어학과

2026년 11월 4일 수요일

지난 시간에 배운 것

1. XML은 이름이 값을 감싸고, 목록은 같은 이름의 요소를 늘어놓아 적는다.
2. `ElementTree`의 `find`, `findall`, `iter`로 경로를 따라 요소를 꺼냈다.
3. 사전의 파일 88개를 표제어 표로 펼쳐 `headwords.csv`(439,566행)로 남겼다.

오늘의 목표

1. 정규표현식으로 동형어 번호를 떼고 논문의 후보 목록을 다시 만들 수 있다.
2. 표제어에서 어간을 얻고, 끝 음절의 받침을 9강의 산수로 꺼낼 수 있다.
3. 논문의 표를 사전의 기준값과 나란히 놓고, 두 수가 무엇을 말해 주는지 읽을 수 있다.
4. 남이 같은 수를 얻으려면 무엇을 남겨야 하는지 말할 수 있다.

사전 준비 (1) Codespace와 노트북

Codespaces에서 할 일

1. 2강에서 만든 Codespace를 연다. (새로 만들지 않는다)
2. Explorer의 [New File...]를 눌러 저장소 **맨 위**에 `15-adjectives.ipynb`를 만든다.
3. 오른쪽 위 [Select Kernel] → [Python Environments] → Python 3.12.x

노트북 `15-adjectives.ipynb`의 첫 셀

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

sns.set_theme(style='whitegrid', font='NanumGothic')
```

사전 준비 (2) 14강의 CSV

터미널 입력

```
cd /workspaces/LDS2026
wc -l data/stdict/headwords.csv
```

실행 결과

```
439567 data/stdict/headwords.csv
```

오늘은 XML을 읽지 않는다. 14강이 남긴 CSV에서 시작한다.

줄 수가 다르거나 파일이 없으면

머리줄 하나와 행 439,566개다. `No such file or directory`가 나오면 14강의 사전 준비(zip 올리기, 압축 풀기)를 다시 하고 `14-xml.ipynb`를 [Run All]로 돌린다. 1분쯤 걸린다.

1 **논문 다시 보기**
후보 목록과 두 설명

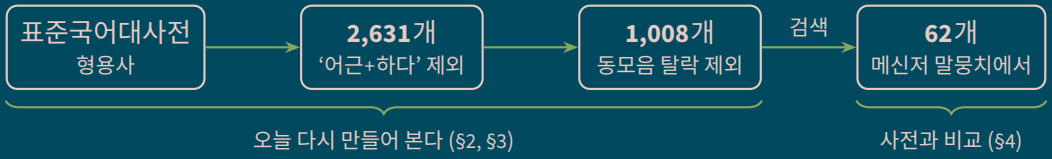
2 2,631 다시 만들기

3 어간과 받침

4 논문의 표와 사전

5 마무리

논문이 한 일



62개에서 찾은 것 (표 3, 표 4)

- 어간의 음절 수: 2음절이 35개로 **56.5%**
- 닫힌 음절(받침 있는 음절)로 끝나는 어간 57개 가운데 끝 받침이 ‘ㅂ’인 것이 37개로 **64.9%**

출처: 임건수(2025) 191쪽, 198–199쪽

논문의 두 설명

표 3 아래 (198쪽)

“2음절의 어간이 빈도가 높은 이유는 **형용사에서 2음절이 많기 때문**으로 보인다.”

표 4 아래 (199쪽)

“종성 ‘ㅂ’가 높은 빈도로 나타나는 이유는 ‘ㅂ’가 **형용사 어간의 끝소리로 흔히 나타나는** 음운적 특성이기 때문일 것이다.”

둘 다 사전에 대한 말이다

말뭉치에서 찾은 62개가 아니라 **형용사 전체**가 어떻다는 말이다. 그렇다면 사전의 형용사를 세어 확인할 수 있다. 사전에서 2음절과 ‘ㅂ’은 원래 몇 %일까? 이 수를 **기준값**이라 부르자. 기준값을 알아야 56.5%와 64.9%가 많은지 말할 수 있다.

1 논문 다시 보기

2 **2,631 다시 만들기**
동형어 번호
후보 2,652개

3 어간과 받침

4 논문의 표와 사전

5 마무리

지난 시간의 셈

노트북 입력

```
headwords = pd.read_csv('data/stdict/headwords.csv')
adj = headwords[headwords['pos'] == '형용사']
print(len(adj))
hada = adj['word'].str.endswith('-하다')
print(hada.sum(), (~hada).sum())
```

실행 결과

```
13400
7747 5653
```

~hada True와 False를 뒤집는다(10강). '-하다'로 끝나지 **않는** 행이다

남은 5,653행은 논문의 2,631개보다 두 배 넘게 많다. 무엇이 남았는지 들여다본다.

끝 글자를 보면

노트북 입력

```
rest = adj.loc[~hada, 'word']
print(rest.str[-1].value_counts().head(5).to_dict())
```

실행 결과

```
{'다': 2530, '2': 1310, '1': 1283, '3': 334, '4': 112}
```

`str[-1]` 문자열마다 마지막 글자. Python의 `w[-1]`을 열 전체에 한다

형용사인데 '다'로 끝나지 않는 표제어가 3,123행이다. 끝이 숫자다.

‘창연-하다02’

노트북 입력 — 14강이 예고한 표제어

```
print(headwords[headwords['word'].str.startswith('창연-하다')])
```

실행 결과

	target_code	word	word_unit	word_type	pos
362949	483736	창연-하다01	단어	혼종어	형용사
362950	319437	창연-하다02	단어	혼종어	형용사
362951	483738	창연-하다03	단어	혼종어	형용사

창연-하다01 몹시 서운하고 섭섭하다.
창연-하다02 드높아 시원스럽다.
창연-하다03 빛깔이 몹시 푸르다.

셋 다 ‘어근+하다’인데 끝이 ‘다’가 아니라 번호라서 `endswith('-하다')`에 걸리지 않았다.

동형어 번호

글자는 같고 뜻이 다른 표제어

사전은 글자가 같은 표제어(동형어)를 번호로 가른다. XML은 그 번호를 표제어 끝에 **두 자리 숫자**로 붙여 적었다.

표제어	품사	뜻풀이
곱다01	동사	이익을 보려다가 도리어 손해를 입게 되다.
곱다02	형용사	모양, 생김새, 행동거지 따위가 산뜻하고 아름답다.
곱다03	형용사	손가락이나 발가락이 얼어서 감각이 없고 놀리기가 어렵다.

번호는 표제어의 일부가 아니다

‘곱다02’와 ‘곱다03’은 둘 다 ‘곱다’다. 끝 글자로 무엇을 가르려면 번호부터 떼야 한다. 14강의 표에서 번호가 붙은 형용사는 3,123행으로, 형용사의 4분의 1에 가깝다.

번호 떼기

노트북 입력

```
adj['lemma'] = adj['word'].str.replace(r'[0-9]+$', '', regex=True)
print((adj['word'] != adj['lemma']).sum())
print(adj.loc[adj['word'] == '창연-하다02', 'lemma'].tolist())
```

실행 결과

```
3123
['창연-하다']
```

`[0-9]+$` 숫자 한 자리 이상, 그리고 바로 뒤가 끝(4강)

`regex=True` 앞의 글을 정규표현식으로 읽으라는 뜻이다. 빠뜨리면 글자 그대로 `[0-9]+$`를 찾는다

`lemma`는 번호를 뗀 표제어다. 고친 것은 `word`가 아니라 새 열이다. 원래 표제어는 그대로 남겨 둔다.

후보 2,652개

노트북 입력

```
cand = adj[~adj['lemma'].str.endswith('-하다')]
print(len(cand), cand['target_code'].nunique(), cand['lemma'].nunique())
```

실행 결과

```
2652 2652 2626
```

2652 행. 형용사이면서 '-하다'로 끝나지 않는 표제어

2652 표제어 번호. 한 행이 표제어 하나다

2626 번호를 뗀 표제어. '곱다02'와 '곱다03'이 하나가 되어 26이 줄었다

논문의 2,631개에 바짝 다가갔다. 그런데 2,652로 셀까, 2,626으로 셀까?

형용사이기만 한 것은 아니다

노트북 입력

```
other = headwords.loc[headwords['pos'] != '형용사', 'target_code']
print(cand['target_code'].isin(other).sum())
print(*cand.loc[cand['lemma'].str.endswith('하다'), 'lemma'])
```

실행 결과

```
44
그럴-듯하다 되지-못하다 마지-못하다 맵-싸하다 못지-아니하다 볼-만하다 속-상하다 얼토당토-아니하다
```

`isin(other)` 품사가 둘 이상인 표제어(14강의 '바삭-하다')를 찾는다

`print(*…)` 열의 값을 빈칸으로 이어 한 줄에 찍는다

아래 8개는 붙임표가 '하다' 바로 앞에 없어 남았다. 이것도 '어근+하다'일까?

2,652와 2,631 사이

무엇을 셌나	수
형용사 행에서 번호를 떼고 '-하다'로 끝나는 행을 뺀다	2,652
번호를 뗀 표제어를 하나로 센다	2,626
다른 품사도 있는 44개를 뺀다	2,608
그 가운데 '그럴-듯하다' 같은 8개도 뺀다	2,600
논문	**2,631**

버전이 다르면 수도 다르다

14강에서 본 대로 사전은 해마다 고쳐진다. 논문이 쓴 버전과 오늘의 버전은 다를 수 있다. 21개는 2,631의 1%도 안 되는 차이다. 오늘은 2,652행을 후보로 쓴다.

‘-하다’만 뺐다

노트북 입력 — 마지막 붙임표 뒤를 꺼낸다

```
suffix = cand['lemma'].str.extract(r'-([^-]+)$')[0]
print(suffix.isna().sum())
print(suffix.value_counts().head(6).to_dict())
```

실행 결과

```
573
{'스럽다': 820, '없다': 183, '지다': 159, '롭다': 106, '맞다': 61, '같다': 58}
```

`str.extract` 괄호 안에 잡힌 부분을 꺼낸다(12강). 못 잡으면 NaN

`[^-]+` 붙임표가 아닌 글자 한 자리 이상. 붙임표가 없는 573행(‘부럽다’)이 NaN

‘부담-스럽다’도 어근+접미사인데 남았다. 논문이 뺀 것은 ‘-하다’ **하나**다. 이것이 논문의 조작적 정의(12강)다.

확인 질문

여기까지 정리

1. 14강의 `endswith('-하다')`가 '창연-하다02'를 놓친 까닭은?
2. `str.replace(r'[0-9]+$', '')`에서 `regex=True`를 빠뜨리면 몇 행이 바뀔까?
3. '곱다02'와 '곱다03'을 하나로 세는 것과 둘로 세는 것은 각각 무엇을 세는 것인가?
4. 2,652와 2,631의 차이 21개가 어디서 왔는지 알려면 무엇을 알아야 할까?
5. '부담-스럽다'를 후보에 넣을지 뺄지는 누가 정하는가? 넣으면 무엇이 달라질까?

1 논문 다시 보기

2 2,631 다시 만들기

3 **어간과 받침**
어간
받침

4 논문의 표와 사전

5 마무리

표제어에서 어간으로

노트북 입력

```
cand['stem'] = cand['lemma'].str.replace('-', '').str.removesuffix('다')
cand['syl'] = cand['stem'].str.len()
print(cand.loc[cand['lemma'] == '부럽다', ['word', 'stem', 'syl']])
```

실행 결과

```
        word stem  syl
163528  부럽다   부럽    2
```

`replace('-', '')` 붙임표를 지운다. 정규표현식이 아니니 `regex`는 적지 않는다

`removesuffix('다')` 끝의 '다'를 뗀다(14강의 `'.xml'`). 어간 '부럽'이 남는다

`str.len()` 글자 수. 한글 음절 하나가 한 글자다(9강)

어간의 음절 수

노트북 입력

```
print(cand['syl'].value_counts().sort_index().to_dict())
print(cand.loc[cand['syl'] >= 7, 'lemma'].tolist())
four = cand[cand['syl'] == 4]
print(len(four), four['lemma'].str.endswith('스럽다').sum())
```

실행 결과

```
{1: 95, 2: 580, 3: 1045, 4: 819, 5: 95, 6: 16, 7: 1, 8: 1}
['아니곱살머리-스럽다', '얼토당토-아니하다']
819 711
```

사전에서는 3음절과 4음절이 많다. 2음절은 580개(22%)이고, 4음절 819개 가운데 711개가 '-스럽다'다.

9강의 산수

노트북 입력 — 9강의 셀 그대로

```
CHO  = 'ㄱㄲㄴㄷㄸㄹㅁㅂㅃㅅㅆㅇㅈㅉㅊㅋㅌㅍㅎ'
JUNG = ' ㅏㅐㅑㅒㅓㅔㅕㅖㅗㅘㅙㅚㅛㅜㅝㅞㅟㅠㅡㅢㅣ'
JONG = ' ㄱㄲㄳㄴㄵㄶㄷㄹㄺㄻㄼㄽㄾㄿㅀㅁㅂㅄㅅㅆㅇㅈㅊㅋㅌㅍㅎ'

def decompose(ch):
    code = ord(ch) - 0xAC00
    return CHO[code // 588], JUNG[code % 588 // 28], JONG[code % 28]

print(decompose('럽'), decompose('쁘'))
```

실행 결과

```
('ㄹ', 'ㅓ', 'ㅂ') ('ㅃ', 'ㅡ', ' ')
```

JONG의 맨 앞은 빈칸 하나다. 받침이 없는 음절의 종성은 빈칸 ' ' 으로 나온다.

끝 음절의 받침

노트북 입력

```
def coda(stem):
    return decompose(stem[-1])[2]

cand['coda'] = cand['stem'].map(coda)
print(cand['coda'].value_counts().head(6).to_dict())
```

실행 결과

```
{'ㅂ': 1178, ' ': 627, 'ㅃ': 185, 'ㅎ': 165, 'ㅈ': 109, 'ㄱ': 80}
```

`map(coda)` 열의 값마다 함수를 부른다. 12강에서는 `dict`를 주었다

'부럽', '까다롭'의 ㅂ이 가장 많고, 받침이 없는 어간('바쁘', '고프')이 그다음이다.

열린 음절과 닫힌 음절

노트북 입력

```
closed = cand[cand['coda'] != ' ']
print(len(closed), len(cand) - len(closed))
print((closed['coda'] == 'ㅂ').mean().round(3))
```

실행 결과

```
2025 627
0.582
```

닫힌 음절 받침이 있는 음절. 논문의 '폐음절'

열린 음절 받침이 없는 음절. 논문의 '개음절'

분모를 맞춘다

논문의 64.9%는 닫힌 음절로 끝나는 어간 **57개**가 분모였다. 사전도 닫힌 음절 2,025개를 분모로 하면 ㅂ은 **58.2%**다. 2,652개 전체로 나눈 44%는 논문과 비교할 수가 아니다.

동모음 탈락을 빼면

노트북 입력 — 받침 없이 ㅏ, ㅓ, ㅐ, ㅔ로 끝나는 어간

```
def vowel(stem):
    return decompose(stem[-1])[1]
cand['vowel'] = cand['stem'].map(vowel)
same = (cand['coda'] == ' ') & cand['vowel'].isin([' ㅏ', ' ㅓ', ' ㅐ', ' ㅔ'])
print(same.sum(), (~same).sum())
print(cand.loc[same, 'lemma'].head(6).tolist())
```

실행 결과

```
137 2515
['가멸-차다', '가열-차다', '각별-나다', '감때-세다', '값-비싸다', '값-싸다']
```

ㅓ로 끝나는 형용사 어간은 사전에 하나도 없다(‘서다’, ‘건너다’는 동사). 논문이 든 ‘-차다’, ‘-나다’, ‘-세다’가 대부분이고, 남은 것은 **2,515**개다.

1,008에는 닿지 않았다

2,652개에서 무엇을 남겼나	수
동모음 탈락(받침 없이 ㅏ, ㅓ, ㅐ, ㅔ로 끝남)을 뺀다	2,515
그 가운데 고유어만	1,762
그 가운데 '-스럽다', '-롭다', '-되다', '-답다'가 아닌 것	1,527
그 가운데 붙임표가 없는 것('부럽다')	552
닫힌 음절로 끝나는 것만	2,025
논문	**1,008**

기준을 코드로 남긴다

논문은 2,631개를 1,008개로 줄였다. 동모음 탈락 말고도 기준이 더 있었을 텐데, 논문 한 편에 그 세부를 모두 싣기는 어렵다. 우리가 고른 기준은 코드로 남겨 두어, 누구나 같은 수를 얻게 한다.

1 논문 다시 보기

2 2,631 다시 만들기

3 어간과 받침

4 **논문의 표와 사전**
표 2의 62개
음절 수와 받침
저장소에 남기기

5 마무리

표 2를 옮겨 적는다

노트북 입력 — 논문 195쪽의 어간 62개, 음절 수 차례대로

```
paper = '''없 같 있 않 싫 많 맵 춥 늙 젊 좁 덥
부럽 무섭 귀찮 귀엽 아쉽 고맙 괜찮 힘들 아깝 어렵 맛있 똑같
지겹 괴롭 가깝 고프 수줍 무겁 맛없 외롭 멋있 이쁘 바쁘 아프
슬프 놀랍 두껍 졸립 더럽 반갑 어둡 해맑 그립 해롭 서럽
안타깝 안쓰럽 까다롭 부끄럽 시끄럽 어이없 재미없 뜬금없
필요없 정신없 번거롭 부담스럽 당황스럽 의문스럽 조심스럽'''.split()
print(len(paper), len(set(paper)))
```

실행 결과

```
62 62
```

`split()`은 빈칸과 줄바꿈 어디서나 자른다. 따옴표 셋(`'''`)은 여러 줄 문자열이다(14강). 괄호 안의 빈도는 옮기지 않았다. 오늘은 타입만 센다.

후보에 없는 셋

노트북 입력

```
p = pd.DataFrame({'stem': paper})
p['in_cand'] = p['stem'].isin(cand['stem'])
print(p['in_cand'].sum(), p.loc[~p['in_cand'], 'stem'].tolist())
```

실행 결과

```
59 ['않', '늙', '필요없']
```

셋은 오늘의 후보 2,652개에 없다. 사전 전체에서 찾아본다.

셋은 사전의 어디에

노트북 입력 — 모든 표제어를 같은 방법으로 어간으로

```
stem_all = (headwords['word'].str.replace(r'[0-9]+$', '', regex=True)
            .str.replace('-', '').str.removesuffix('다'))
found = stem_all.isin(['않', '늙', '필요없'])
print(headwords.loc[found, ['word', 'pos']])
```

실행 결과

	word	pos
81074	늙다	동사
240553	않다	동사
240554	않다	보조 동사
240555	않다	보조 형용사

늙 사전에서 '늙다'는 동사뿐이다

않 형용사가 아니라 보조 형용사다

필요없 표제어가 없다. '필요 없다'는 두 단어이다

논문은 사전의 품사에 매이지 않고 메신저에서 쓰인 어간을 함께 담은 듯하다.

음절 수를 나란히

노트북 입력

```
p['syl'] = p['stem'].str.len()
p['coda'] = p['stem'].map(coda)
syl = pd.DataFrame({'논문': p['syl'].value_counts(normalize=True),
                    '사전': cand['syl'].value_counts(normalize=True)})
print((syl.loc[1:4] * 100).round(1))
```

실행 결과

syl	논문	사전
1	19.4	3.6
2	56.5	21.9
3	17.7	39.4
4	6.5	30.9

`normalize` 개수 대신 비율. 62개와 2,652개처럼 크기가 다른 둘은 비율로 비교한다(12강)

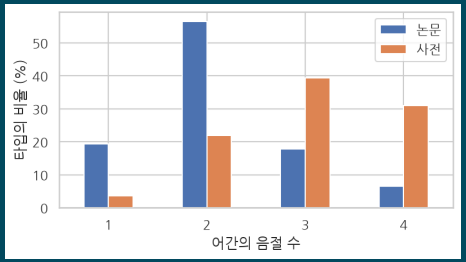
`loc[1:4]` 색인 1부터 4까지. 논문에 없는 5음절 이상은 뺐다

논문 쪽은 표 3의 비율과 소수 첫째 자리까지 같다.

막대그림으로

노트북 입력

```
ax = (syl.loc[1:4] * 100).plot.bar(figsize=(6, 3), rot=0)
ax.set_xlabel('어간의 음절 수')
ax.set_ylabel('타입의 비율 (%)')
plt.savefig('plots/stem-syllables.png', dpi=150, bbox_inches='tight')
```



plot.bar는 행마다 세로 막대 묶음을, 열마다 색을 하나씩 쓴다(12강의 barh를 세운 것). rot=0은 아래 눈금 글자를 눕히지 않는다.

2음절은 원래 많지 않다

사전이 기준값이라면

사전의 형용사에서 2음절 어간은 21.9%다. 62개를 사전에서 아무렇게나 뽑았다면 2음절은 $62 \times 0.219 \approx 14$개쯤이어야 한다. 논문에서는 **35개**다.

사전 전체를 기준으로 하면

사전에서 가장 많은 것은 3음절(39.4%)과 4음절(30.9%)이고, 1음절은 3.6%다(논문 19.4%). 사전 전체의 비율만으로는 62개에 2음절이 많은 까닭을 다 설명하기 어렵다.

논문이 말한 '형용사'가 **자주 쓰는** 형용사라면 이야기가 달라질 수 있다. 뒤에서 다시 본다.

받침을 나란히

노트북 입력 — 닫힌 음절로 끝나는 것만

```
pc = p[p['coda'] != ' ']
codas = pd.DataFrame({
    '논문': pc['coda'].value_counts(normalize=True),
    '사전': closed['coda'].value_counts(normalize=True)})
print((codas.loc[['ㅂ', 'ㅃ', 'ㅎ', 'ㅆ']].fillna(0) * 100).round(1))
```

실행 결과

coda	논문	사전
ㅂ	63.2	58.2
ㅃ	12.3	9.1
ㅎ	0.0	8.1
ㅆ	5.3	0.6

`fillna(0)` 논문에 없는 받침(‘하얗다’의 ㅎ)은 NaN이 되므로 0으로 채운다(7강)

분모는 논문 57개, 사전 2,025개다. 표 4의 ㅂ은 64.9%인데 여기서는 63.2%다. 다음 쪽에서 살핀다.

ㅂ과 ㅄ

노트북 입력

```
print(pc['coda'].value_counts().to_dict())
```

실행 결과

```
{'ㅂ': 36, 'ㅄ': 7, 'ㄶ': 4, 'ㅆ': 3, 'ㅌ': 2, 'ㄺ': 2, 'ㄻ': 1, 'ㄿ': 1, 'ㄹ': 1}
```

	ㅂ 타입	ㅂ 비율	ㅄ 타입	ㅄ 비율
논문 표 4	37	64.9%	6	10.5%
표 2의 어간을 함수로 나눔	36	63.2%	7	12.3%

ㅄ은 발음으로는 [ㅂ]이라(199쪽, 자음군 단순화) 어느 칸에 둘지가 갈릴 수 있는 받침이다. 우리 함수는 글자만 보고 나눈다. 어느 쪽으로 세어도 **ㅂ이 가장 많다**는 것은 같다.

ㅂ은 원래 많다

사전이 기준값이라면

사전에서 닫힌 음절로 끝나는 형용사 어간의 58.2%가 ㅂ이다. 57개를 아무렇게나 뽑았다면 ㅂ은 $57 \times 0.582 \approx 33$개쯤이다. 논문에서는 36개(표 4로는 37개)다.

사전의 수가 둘째 설명을 뒷받침한다

"ㅂ가 형용사 어간의 끝소리로 흔히 나타나는" 것은 사전에서도 확인된다. ㅂ이 많은 까닭의 대부분은 **원래 많아서**로 설명된다. 기대보다 3개쯤 많다. 2음절은 기대보다 21개 많았다.

두 설명, 두 결과

두 설명은 모두 사전에 대한 말이라 세어 볼 수 있었다. 하나는 사전의 수와 잘 맞고, 다른 하나는 무엇을 기준값으로 삼을지 더 생각하게 한다(다음 쪽).

사전은 쓰이는 말이 아니다

오늘의 기준값이 센 것

사전의 표제어는 드문 말도 자주 쓰는 말도 **하나씩** 센다. '아니꼽살머리-스럽다'도 '부럽다'도 1이다. 4음절의 대부분인 '-스럽다' 711개 가운데 메신저에서 쓰이는 것은 얼마 되지 않을 것이다.

더 나은 기준값

메신저 말뭉치에서 **어미와 함께** 쓰인 형용사를 타입으로 모아 음절 수와 받침을 센다. 어미 없이 쓰인 62개를 그것과 비교하면 '자주 쓰는 말이라 짧다'는 설명과 '짧아서 어미 없이 쓴다'는 설명을 가를 수 있다. 11강의 말뭉치와 10강의 형태소 분석기로 할 수 있는 일이다.

무엇을 기준값으로 삼느냐가 결론을 바꾼다. 기말프로젝트에서 비율을 말할 때도 '무엇에 비해서'를 먼저 정한다.

확인 질문

논문의 표와 사전

1. 논문의 64.9%와 비교할 사전의 수가 44%가 아니라 58.2%인 까닭은?
2. ‘않’, ‘늙’, ‘필요없’은 사전의 형용사가 아닌데 메신저에서 어미 없이 쓰였다. 무엇을 말해 주는가?
3. 사전에서 2음절 어간이 21.9%인데 62개 가운데 35개가 2음절이다. 이것으로 말할 수 있는 것과 없는 것은?
4. ㅄ을 ㅂ과 함께 셀지 따로 셀지에 따라 무엇이 달라지고, 무엇이 그대로인가?
5. ‘부럽’, ‘무섭’처럼 **자주** 쓰는 형용사의 음절 수를 기준값으로 삼으려면 무엇을 세어야 할까?

무엇을 남길까

터미널 입력 — 노트북이 목록에 없으면 Ctrl+S로 저장부터 한다

```
cd /workspaces/LDS2026
git status
```

실행 결과

```
On branch main
Your branch is up to date with 'origin/main'.

Untracked files:
  (use "git add <file>..." to include in what will be committed)
        15-adjectives.ipynb
        plots/stem-syllables.png

nothing added to commit but untracked files present (use "git add" to track)
```

커밋하기

터미널 입력

```
git add 15-adjectives.ipynb plots/stem-syllables.png
git commit -m "15강 실습 노트북: 사전 형용사의 음절과 받침"
```

실행 결과

```
[main a1b2c3d] 15강 실습 노트북: 사전 형용사의 음절과 받침
 2 files changed, 668 insertions(+)
 create mode 100644 15-adjectives.ipynb
 create mode 100644 plots/stem-syllables.png
```

노트북과 그림만 올라간다. 오늘은 새 데이터 파일을 만들지 않았다. `headwords.csv`는 여전히 `data/` 아래에 있다.

푸시하기

터미널 입력

```
git push
```

실행 결과

```
Enumerating objects: 7, done.
Writing objects: 100% (5/5), 32.63 KiB | 32.63 MiB/s, done.
To https://github.com/your-username/LDS2026.git
   e4f5a6b..a1b2c3d  main -> main
```

버전과 방법을 남긴다

사전의 버전(20261012), 무엇을 '-하다'로 쳤는지, 동모음 탈락을 어떻게 가렸는지가 모두 코드로 남았다. 2,652를 어떻게 얻었는지 누가 물어도 이 노트북을 보여 주면 된다.

1 논문 다시 보기

2 2,631 다시 만들기

3 어간과 받침

4 논문의 표와 사전

5 **마무리**
- 요약
- 다음 시간
- 과제

오늘 쓴 것

하는 일	오늘의 코드
끝의 번호 떼기	`s.str.replace(r'[0-9]+$', '', regex=True)`
글자 그대로 지우기	`s.str.replace('-', '')`
끝 글자, 끝의 '다'	`s.str[-1]`, `s.str.removesuffix('다')`
괄호로 잡아 꺼내기	`s.str.extract(r'-([^-]+)$')[0]`
글자 수	`s.str.len()`
값마다 함수 부르기	`s.map(coda)`
다른 표에 있는가	`s.isin(other)`
크기가 다른 둘을 비율로	`s.value_counts(normalize=True)`
세로 막대그림	`df.plot.bar(rot=0)`

새로 배운 함수는 거의 없다. 4강의 정규표현식, 9강의 decompose, 12강의 비율을 **사전에** 썼다.

오늘 배운 것

후보 목록

- 동형어 번호를 떼야 '-하다'가 보인다
- 2,652개. 논문의 2,631과 21 차이
- 1,008에는 닿지 않았다

논문과 사전

- 2음절: 논문 56.5%, 사전 21.9%
- ㅂ: 논문 64.9%, 사전 58.2%
- 기준값으로 설명을 확인한다

어간과 받침

- 붙임표와 '다'를 떼면 어간
- 끝 음절의 종성은 % 28
- 받침이 없으면 빈칸 ' '

기준값

- 분모를 맞추어 비교한다
- 사전은 쓰이는 말이 아니다
- 방법을 적어야 다시 할 수 있다

확인 질문

오늘 것을 정리해 봅시다

1. ‘곱다03’에서 ‘곱’을 얻는 코드를 오늘 쓴 `str` 함수 셋으로 적어 보자.
2. `decompose('괜')`과 `coda('괜찮')`은 각각 무엇을 돌려주는가?
3. 논문의 두 설명 가운데 사전의 수와 잘 맞는 것은? 다른 하나에는 어떤 기준값이 어울릴까?
4. 우리의 2,652가 논문의 2,631과 다를 수 있는 까닭을 둘 들어 보자.
5. 여러분의 기말프로젝트에서 ‘많다’고 말할 수 하나를 골라, 그 기준값이 무엇인지 적어 보자.

다음 시간에 배울 것 (11월 9일 월요일)

제16강 HuggingFace 데이터 활용

남이 공개해 둔 언어 데이터셋을 HuggingFace Hub에서 찾아 `load_dataset`으로 내려받는다. 데이터셋 카드에서 무엇을 모았는지, 어떻게 나누었는지, 라이선스가 무엇인지 읽는다.

미리 생각해 둘 것

오늘 논문과 같은 수를 얻으려면 사전의 버전과 셈의 세부가 필요했다. 남이 만든 데이터셋을 쓰려면 그 데이터셋에 대해 **무엇이 적혀 있어야** 할까?

기말프로젝트 중간발표가 다가온다

[숙제10]에서 정한 주제의 데이터를 이번 주에 모으기 시작하자. HuggingFace가 그 길 하나다.

과제 안내

[숙제11] 강의중간평가 인증 [인증]

마감 **2026-11-05 23:59 (목요일)**. 강의중간평가 기간(10/29–11/5)에 참여하고 eTL에 인증한다.

[숙제12] 기말프로젝트 중간발표 자료 [보고서]

마감 **2026-11-13 12:00 (금요일 정오)**. 발표는 11월 16일(월)과 18일(수) 두 번에 나누어 한다.

[숙제00심화] 논문의 통계량 · 시각화 재검토 (선택)

오늘 사전의 기준값을 세어 본 것처럼, 읽은 논문의 수를 데이터로 다시 살펴보자. eTL 심화과제 게시판에 공개글로, 12월 18일 09:00까지 수시로 올린다.